Zynq 皮肤病变智能预筛终端
——基于 PS/PL 异构协同的 CNN 加速预筛系统

摘要

皮肤疾病种类多、分布广，是全球前十的致残原因之一。针对普通摄像条件下皮肤病变图像易受光照和抖动影响，以及边缘设备对实时性与隐私保护的需求，设计了一套基于 AMD Zynq 异构计算的皮肤病变规范化采集与可解释风险预筛终端。系统以 PYNQ-Z2 为平台，将实时取景、质量检测、自动抓拍、CNN 推理、结果显示和本地存档连接为连续流程。PL 侧采用流水线结构处理 720p60 视频，完成曝光与清晰度检测、取景框叠加和轻量 CNN 定点推理；PS 侧负责抓拍复核、输入预处理、三帧融合、界面交互及文件管理。图像连续通过质量检测后自动抓拍并进入推理，界面同步显示质量未通过原因、风险概率、判定阈值和多帧融合结果，使采集与判定过程可以核对。板级测试表明，系统能够稳定完成视频预览、质量门控、单帧及三帧融合预筛，模型量化与硬件部署在降低存储和处理开销的同时保持了风险预筛性能。系统支持结果自动保存和导出，原始皮肤图像无需上传云端，可为基层医疗、社区健康服务和义诊巡检提供本地化风险预筛支持。

关键词： Zynq 异构计算；皮肤病变风险预筛；规范化图像采集；图像质量门控；CNN 硬件加速

目录

1. 选题背景与作品概述 1

1.1 选题背景与应用需求 1

1.2 现有相关作品分析 2

1.3 作品功能 3

1.4 解决的实际问题与应用价值 3

1.5 主要创新点 4

2. 设计原理与总体方案 5

2.1 系统设计原理与功能流程 5

2.2 Zynq 异构架构与软硬件划分 7

2.3 系统数据通路与接口设计 9

3. 关键模块设计与实现 11

3.1 视频采集与显示通路 11

3.1.1 720p HDMI 视频输入与颜色格式转换 13

3.1.2 VDMA 与 DDR 帧缓存 13

3.1.3 主视频通路与质量检测支路并行设计 14

3.1.4 质量状态取景框叠加与 HDMI 输出 14

3.1.5 视频通路板级实现结果 15

3.2 图像质量门控与自动抓拍 15

3.2.1 中心检测区域与亮度计算 16

3.2.2 曝光质量检测 17

3.2.3 Sobel 清晰度检测 17

3.2.4 连续合格判定、抓拍复核与单张保存 18

3.2.5 参数配置与帧级同步控制 20

3.2.6 阈值选取依据与板级验证结果 20

3.3 CNN 模型训练与量化部署 22

3.3.1 数据集划分与二分类任务定义 22

3.3.2 输入图像预处理 23

3.3.3 轻量化 CNN 网络结构 23

3.3.4 模型训练与模型选择 24
3.3.5 INT8 量化与 PL 部署格式转换 24
3.3.6 测试集性能与模型存储开销 26
3.4 CNN 推理加速电路 28
3.4.1 加速电路架构与网络映射 28
3.4.2 定点计算、片上存储与并行调度 29
3.4.3 PS/PL 接口与推理任务控制 30
3.4.4 实现结果与数值一致性验证 31
3.5 PS 端控制与交互程序 32
3.5.1 菜单模式、按钮交互与系统状态控制 32
3.5.2 实时预览与质量状态显示 33
3.5.3 自动抓拍与 CNN 输入生成 33
3.5.4 单帧推理、三帧融合与风险结果显示 34
3.5.5 结果自动保存与可选导出 35
3.5.6 异常处理与下一次采集控制 36
4. 工程优化过程 36
4.1 模型训练与量化优化 36
4.2 CNN 加速电路迭代优化 38
4.3 图像质量门控优化 40
4.4 系统优化与 PS/PL 联合调试 42
5. 整机实现与综合验证 45
5.1 整机实物与硬件连接 45
5.2 完整操作流程与交互界面 46
5.3 系统级性能、资源占用与稳定性 48
6. 大模型协作记录 51
6.1 协作定位与任务组织 52
6.2 工具反馈与分层验证 52
6.3 典型协作与纠错过程 53
6.4 记录归档与责任边界 55

7. 技能包提炼与复用 55
7.1 技能包提炼目标与问题来源 56
7.2 技能包内容与适用边界 57
7.3 技能包复用与有效性验证 58
8. 项目复现说明 60
8.1 复现包组成与文件说明 60
8.2 板端部署与系统启动 61
8.3 功能复现与结果检查 62
9. 总结与展望 63
9.1 工作总结 63
9.2 后续展望 64
参考文献 65

1. 选题背景与作品概述

1.1 选题背景与应用需求

皮肤疾病种类多、分布广，是基层医疗和日常健康服务中不可忽视的问题。世界卫生组织基于 2021 年全球疾病负担研究指出，皮肤及皮下组织疾病每年新发病例约 46.9 亿例，造成约 4190 万伤残调整寿命年，已成为全球前十位致残原因之一[1]。在我国，2011—2023 年公立医院皮肤科门诊量累计达到 13.6 亿人次，皮肤疾病相关医疗需求长期处于较高水平[2]。

庞大且持续增长的就诊需求，与有限的皮肤科专业资源之间形成了明显矛盾。截至 2022 年末，我国执业（助理）皮肤科医师约 3.1 万人，先进诊断设备更多集中在一线城市和三级医院；在受访医师中，超过半数每半天需要接诊 30～50 名患者[3]。县域、乡镇和社区医疗机构因专科医生数量有限、专业设备配置不足，难以持续开展皮肤病变的早期筛查，而依靠颜色、边界、纹理及形态进行人工判断又要求基层医护人员具有丰富的经验。

随着这类问题集中暴露，基层医疗和现场筛查对设备的便携性、实时性与结果可靠性提出了更高要求，亟需一种能够完成实时取景、拍摄质量判断、规范化图像采集和风险预筛的一体化设备。该设备应在拍摄阶段主动识别曝光异常和图像模糊，并以直观方式输出筛查结果，为受检者是否需要进一步就医提供参考。

FPGA 可通过像素级并行和流水线结构直接处理连续视频流，在数据传输过程中同步完成颜色转换、质量统计与取景框叠加，减少处理器逐像素串行计算产生的等待。其确定性时延、定点运算效率和可重构特性适合部署轻量 CNN，并可依据芯片资源调整计算并行度。AMD 作为全球主要的高性能与自适应计算企业，在 FPGA 方面有完整的技术体系。AMD Zynq-7000 器件在单芯片内集成 ARM 处理系统和 FPGA 可编程逻辑，使 PL 承担实时视频处理与 CNN 推理，PS 完成流程控制、界面交互和结果管理，为构建低资源、本地化的皮肤病变预筛终端提供了适合的异构平台[4]。

1.2 现有相关作品分析

现有医学图像智能分析方案主要采用移动端与服务器协同、Zynq 异构计算以及 FPGA 实时视频分析等技术路线。不同路线分别在模型规模、使用便利性和实时处理方面具有优势，以下选取与本项目应用方向或技术路径较为接近的获奖作品，分析其技术特点、可借鉴之处及与本项目的差异。

中南大学 AIMADS 团队开发的“AI 知肤宝”在 2019 年中国高校计算机大赛中获得全国总决赛特等奖[5]。该系统基于临床图像和病史数据建立皮肤疾病分类模型，并通过小程序向用户提供服务。其核心技术是由移动端采集患处图像，再将图像发送至服务器，由服务器端卷积神经网络完成分类并返回结果[6]。这种方式便于集中部署计算量较大的模型和统一更新服务，但推理过程需要通信链路和服务器支持。敏感图像离开采集终端后的传输、存储和访问过程还需要采取相应的隐私保护措施[7]。

东南大学全国一等奖作品“基于 PYNQ 的三维医学图像重建”使用 Vitis HLS 和 Vivado 完成算法硬件化，并通过 PS 与 PL 协同实现医学图像重建和实时渲染[8][9]。该作品证明了 PYNQ 平台能够在板端完成计算密集型医学图像任务，为本项目的技术路径提供了重要参考。但是该作品的重点是对已有医学图像数据进行三维重建与显示，并未涉及实时取景、拍摄质量判断、自动抓拍和风险预筛等前端流程。

全国大学生嵌入式芯片与系统设计竞赛国家一等奖作品“基于 FPGA 的内窥镜实时诊断系统”在 FPGA 端部署轻量级病变识别模型，完成消化道病变的实时识别[10]。该作品的视频流处理与轻量模型部署方式对本项目具有较强参考价值，但其输入来自专用内窥镜，成像环境相对固定。而普通摄像头下的皮肤病变采集容易受到拍摄距离、环境亮度、图像清晰度和取景位置变化等影响。

上述作品分别验证了服务器端皮肤病分析、Zynq 医学图像加速和 FPGA 实时病变识别的可行性，为本项目的模型部署、异构计算和实时视频处理提供了参考。但三类方案尚未解决隐私保护、有限资源下应用及采集质量波动的问题，本项目将在后续章节中结合皮肤病变现场采集需求说明具体设计。

1.3 作品功能

系统面向皮肤病变的现场采集与风险预筛。操作者通过板载按键进入工作菜单，可选择单帧推理模式或三帧融合推理模式，并可选择进入结果导出界面。进入采集后，显示屏输出 720p HDMI 实时画面并叠加取景框。PL 侧持续计算取景区域的亮度、曝光和清晰度，UI 同步显示质量指标、连续合格帧数及未通过原因；当采集画面通过质量门控和抓拍复核后，系统自动保留合格图像作为本次推理输入。

在单帧推理模式下，系统对一次合格抓拍完成预处理、CNN 推理和结果保存；在三帧融合推理模式下，系统依次获得三张合格图像，分别完成推理后融合三次结果，以降低单次采集波动对风险判断的影响。抓拍图像经 PS 侧裁剪、缩放和格式转换后送入 PL 侧轻量 CNN 推理电路，PS 依据模型输出和实际判定阈值生成风险提示。PS 与 PL 通过数据通路和控制接口联合运行，使流程调度、图像处理和硬件推理在同一系统中协同完成。

结果界面显示最终风险提示、模型风险概率、判定阈值、参与推理帧数、推理耗时和抓拍图像；三帧融合模式同时列出各帧推理概率。系统自动保存抓拍图像和推理结果，并支持通过按键再次采集、返回菜单或导出已保存结果。

1.4 解决的实际问题与应用价值

普通摄像头采集皮肤病变图像时，环境光照、拍摄距离和手持抖动容易造成过暗、过亮或模糊，进而影响后续模型推理的可靠性。本项目将曝光和清晰度检测前移至图像采集阶段，通过取景框状态和质量判定结果引导操作者调整画面，并在图像连续满足设定条件后自动抓拍，从源头减少明显不合格图像进入 CNN 推理流程。

边缘终端还需要同时完成实时视频预览、图像质量检测、CNN 推理和界面交互。如果这些任务主要依赖 PS 串行执行，连续像素处理容易占用较多处理器时间。本项目将视频流处理、质量统计和 CNN 推理等计算密集型任务部署在 PL 侧，将流程控制、图像预处理、结果显示和文件管理交由 PS 侧完成。PS

与 PL 在同一芯片上联合运行，使实时计算与系统控制相互配合，降低 PS 侧持续处理视频数据的负担。

针对风险预筛结果缺少判定依据和过程记录的问题，系统在显示最终风险提示的同时，提供图像质量检测原因、模型风险概率、判定阈值和参与推理帧数；三帧融合模式还展示各帧推理概率，使操作者能够从采集质量、模型输出和阈值规则三个层面核对本次结果。抓拍图像和推理结果自动保存，为后续复核及结果导出提供依据。

在基层医疗、社区健康服务和义诊巡检等场景中，系统可以辅助工作人员获得满足设定质量条件的皮肤病变图像，并在板端完成本地风险预筛，为是否需要进一步专业检查提供参考。按键启动、自动抓拍和结果保存降低了现场操作难度，操作者还可以通过按键导出抓拍图像及结果记录。整个处理过程无需上传原始皮肤图像，也不依赖外部网络、独立 GPU 或云端推理服务，有利于保护个人隐私，并减少现场部署所需的外部计算设备。

1.5 主要创新点

PS/PL 异构协同设计：作品以“取景—质检—抓拍—推理—显示—存档”为主线进行软硬件划分。PL 承担视频流处理、质量统计、状态叠加和 CNN 定点推理，PS 承担按钮控制、抓拍调度、输入预处理、结果解释、UI 显示和文件管理。系统围绕数据格式、缓存访问、控制时序和任务状态联合调试，使各模块在同一数据流中协同运行，避免将视频通路、质量检测和 CNN 加速割裂为相互独立的演示模块。

面向低资源器件的轻量 CNN 与定点推理加速：针对 XC7Z020 的资源条件，作品构建参数量为 120834、计算量为 66.85 MMAC 的轻量 CNN，并通过 INT8 量化降低权重存储和乘加运算开销。量化模型进一步映射为 PL 侧推理电路，通过片上存储、逐层调度和并行乘加实现加速，在保持模型预筛能力的同时降低对 PS 处理器的计算占用。模型训练、量化和硬件映射采用联合迭代方式，使算法精度、定点一致性、资源占用和板级时序共同参与方案选择。

面向推理输入的双级质量门控机制：系统在视频采集阶段实时计算中心检

测区域的平均亮度、暗像素比例、亮像素比例和 Sobel 清晰度。PL 侧完成逐像素统计、单帧判定和连续三帧合格判断；PS 侧对实际送达的图像按相同规则复核，连续三张复核合格后选取最后一张用于推理。该机制将视频流统计结果与实际推理输入相衔接，减少曝光异常、图像模糊及缓冲传输差异对后续推理的影响。

构建可解释的风险预筛输出：系统将采集质量、模型输出和判定规则共同纳入结果展示。采集阶段实时显示亮度、清晰度、连续合格帧数及质量未通过原因；推理完成后，结果界面显示模型风险概率、判定阈值、参与推理帧数和最终风险提示，三帧融合模式进一步展示各帧概率与融合概率。通过展示并保存抓拍图像和推理结果，使本次图像为何未通过质量检测、模型输出如何经过阈值形成风险提示均能够被核对。

2. 设计原理与总体方案

本系统围绕皮肤病变图像的规范化采集与本地风险预筛进行设计，将持续运行的视频处理任务与按条件触发的推理任务分开组织。实时取景、图像质量检测和取景框叠加需要逐像素连续处理，由 PL 侧以流水方式完成；模式选择、流程控制、图像预处理、结果判定、界面显示和文件管理具有较多条件分支，由 PS 侧负责。CNN 推理中的卷积计算同样部署在 PL 侧，与视频处理和质量检测并行运行。PS 侧负责流程控制与交互界面，及时响应按键操作、状态切换和结果显示。

系统在采集阶段先判断图像是否满足曝光和清晰度要求，质量条件满足后自动抓拍并复核，合格图像再进入后续推理流程，从而减少模糊、过暗或过亮图像对风险判断的影响。采集、质量门控、抓拍、推理、结果显示和本地保存由统一状态流程连接，构成适用于现场操作的完整工作过程。

2.1 系统设计原理与功能流程

系统启动后首先进入模式选择界面，操作者通过板载按键选择单帧推理、三帧融合推理或结果导出功能。进入采集界面后，摄像头视频经 HDMI 输入并

实时显示在外接显示器上。画面中叠加固定取景框，引导操作者将待筛查区域置于规定范围内。

质量门控电路对取景框覆盖的 640×360 像素区域进行检测，计算区域平均亮度、暗像素比例、亮像素比例和 Sobel 梯度清晰度等指标，并根据预设阈值判断当前图像是否满足采集条件。检测结果以红、黄、绿三种取景框状态和文字原因显示：红色表示图像不满足采集条件，黄色表示当前图像通过但连续合格数量不足，绿色表示 PL 侧连续三帧合格，系统进入抓拍复核阶段。质量不合格时，系统保持实时取景并提示曝光或清晰度问题，但不启动 CNN 推理。

在单帧推理模式下，PL 达到连续三帧合格条件后保持抓拍请求。PS 从帧缓存中复制实际送达的 640×360 原始图像并重新进行质量检测；连续三张图像复核合格后，系统选取最后一张完成缩放和格式转换，形成 128×128 网络输入，随后启动 PL 侧 CNN 推理电路。质量门控的连续判定用于获得一张合格推理图像；三帧融合模式则独立完成三次合格图像采集和三次推理，再对三次原始得分进行融合。

结果界面显示最终风险提示、模型风险概率、判定阈值、参与推理的图像数量和推理耗时。三帧融合模式还显示三幅图像各自的风险概率，使操作者能够了解融合结果的形成过程。系统同步保存抓拍图像、质量指标、推理结果、阈值以及模型和硬件版本信息，并可在板端将完整记录整理为压缩包导出。系统总体功能流程如图 1 所示。

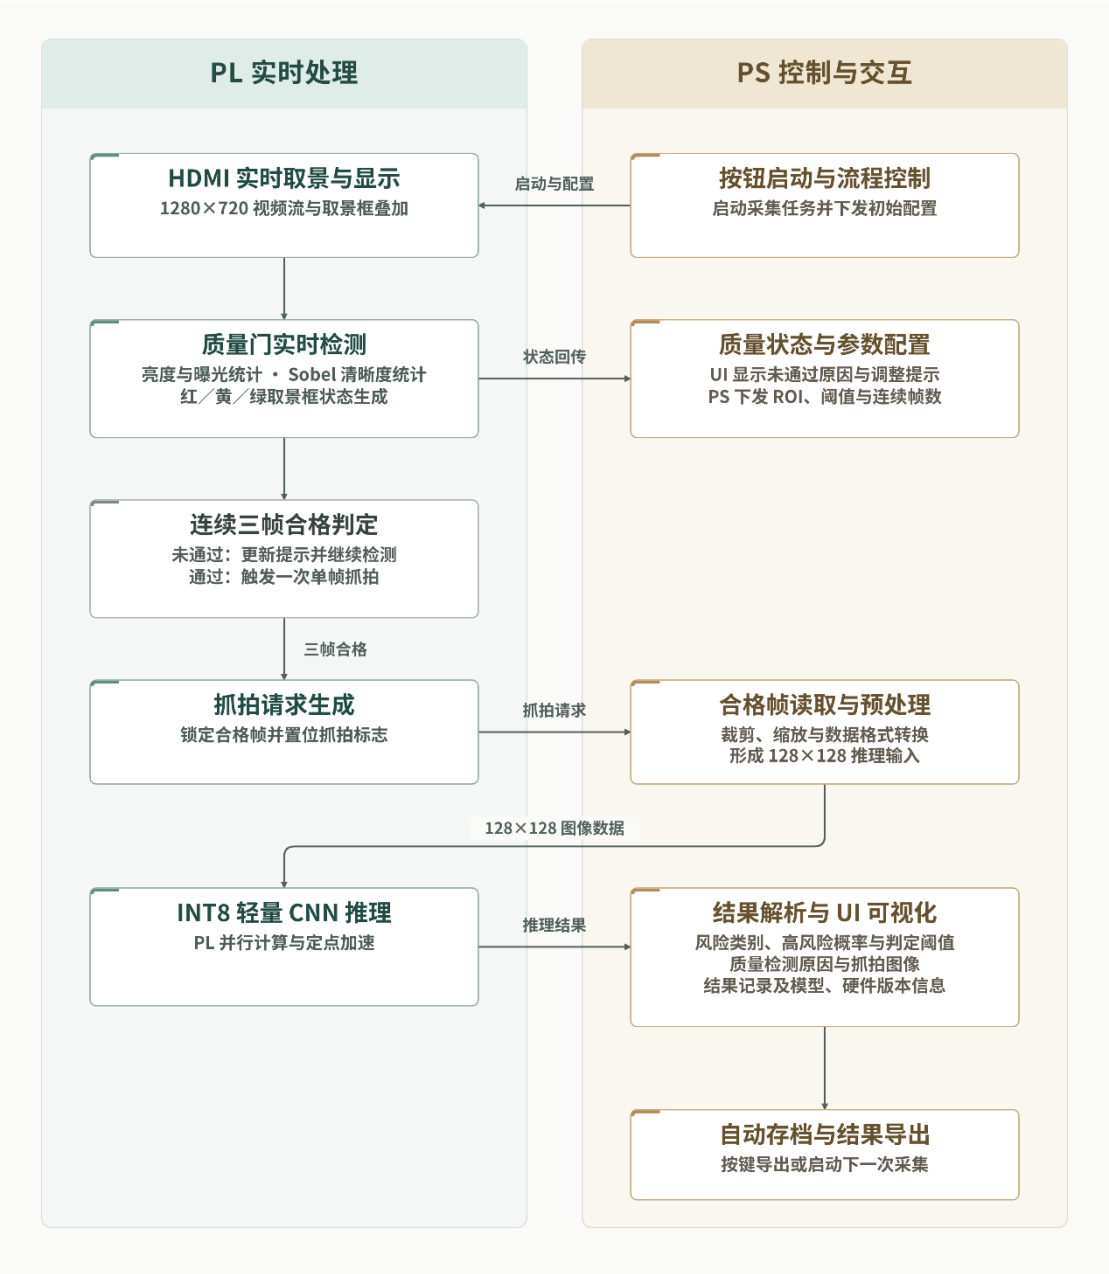


图 1 总体功能流程图

2.2 Zynq 异构架构与软硬件划分

系统基于 AMD Zynq-7000 异构器件实现。器件内部的 PS 包含 ARM 处理器、DDR 控制器及外设接口，适合执行状态控制、数据整理、界面交互和文件系统操作；PL 由可编程逻辑、片上存储和 DSP 资源组成，适合构建逐像素视频流水线和高并行度乘加计算电路。两部分通过 AXI 互连和共享 DDR 交换数据，在单一芯片内完成视频采集、图像质量检测、CNN 推理及结果交互。

软硬件划分以任务的数据组织方式和实时要求为依据。具有固定计算结构、需要持续处理或包含大量重复乘加运算的任务部署在 PL 侧；包含模式切换、条件分支、文件管理和界面组织的任务部署在 PS 侧。具体划分如表 1 所示。

功能模块	实现位置	主要任务	划分依据
HDMI 视频采集与输出	PL	视频输入、像素格式转换、帧缓存传输和 HDMI 显示	需要连续处理视频像素并保持稳定时序
取景框叠加	PL	根据系统状态在输出画面上生成红、黄、绿取景框	属于实时像素级处理，不能阻塞视频通路
图像质量门控	PL	计算亮度、曝光和清晰度指标，完成帧级质量判断	需要对每个输入像素进行统计，适合流水并行处理
轻量 CNN 推理	PL	执行定点卷积、池化和全连接等核心计算	乘加操作密集，可利用 DSP 和片上并行结构加速
工作流程与按键控制	PS	模式选择、状态切换、抓拍调度和异常处理	控制分支较多，功能需要灵活调整
图像预处理与融合判定	PS	图像裁剪缩放、输入整理、得分融合和阈值判定	数据规模可控，便于统一模型前后处理口径
UI 显示、保存与导出	PS	结果页面生成、记录管理和本地压缩包导出	依赖软件界面和文件系统
DDR 帧缓存与共	PS/PL 协同	保存视频帧、抓拍图	为视频通路和推

享数据区		像和推理输入输出	理任务提供统一的数据交换空间

表 1 PS/PL 功能模块划分

PL 侧视频通路在持续输出实时画面的同时完成质量统计，PS 侧同步读取质量状态并更新界面；抓拍条件满足后，PS 从共享帧缓存取得图像并准备网络输入，随后启动 PL 推理核心。在 PL 执行卷积计算期间，PS 仍可处理界面刷新、按键状态和记录管理。推理结束后，PL 返回原始得分，PS 完成概率标定、融合判定、可视化和保存。这样的协同方式使两类处理资源能够按照各自特点工作，并将连续视频、事件触发推理和人机交互组织在同一系统中。

2.3 系统数据通路与接口设计

系统内部包含视频数据通路、推理数据通路和控制状态通路。三条通路通过 VDMA、共享 DDR 和 AXI 接口连接，并由 PS 侧状态机统一调度。

视频数据首先由 HDMI 输入前端转换为 AXI4-Stream 像素流，经过颜色格式转换和流寄存后分为主视频路径与质量分析路径。主路径经像素打包后送入 AXI VDMA，写入 DDR 帧缓存；质量分析路径接收同一位置的 24 位三通道像素流，在不修改原始画面的情况下计算取景区域的亮度、曝光和清晰度指标。PL 侧在完成单帧质量判定后更新连续合格计数，并将质量指标、判定状态和连续合格数量通过状态寄存器送至 PS 侧，用于界面提示和抓拍控制。

显示方向由 VDMA 从 DDR 读取视频帧，经过像素格式恢复后送入取景框叠加模块，再经输出颜色转换和 HDMI 输出模块显示。因为取景框模块位于 DDR 读出之后，所以红、黄、绿状态框只作用于显示画面而不写入抓拍图像和 CNN 输入，避免界面标记干扰质量检测及模型推理。

抓拍条件满足后，PS 从 DDR 中取得 640×360 取景区域并生成 128×128 网络输入。输入数据经共享缓冲区和高性能 AXI 数据通道送入 PL 侧 CNN 推理核心，PS 通过控制寄存器发出启动命令。推理核心完成计算后返回两个类别的原始得分及完成状态。单帧模式直接对本次得分进行标定和判定；三帧融合模式

保留三次独立推理结果，在 PS 侧完成原始得分平均后再进行统一判定。

系统主要接口约定如表 2 所示。

接口类型	传输内容	主要作用
AXI4-Stream 视频接口	24 位三通道像素、帧起始、行结束、有效和就绪信号	连接 PL 侧视频采集、格式转换、质量检测、像素打包及显示模块
AXI VDMA 与 DDR 接口	完整视频帧、抓拍区域和显示帧	完成输入输出视频缓存，并为 PS 访问图像提供共享存储空间
AXI4-Lite 控制接口	ROI 范围、质量阈值、模式配置、启动命令及状态信息	由 PS 配置 PL 模块，并读取质量检测和推理状态
CNN 任务接口	128×128 网络输入、启动/完成状态和二分类原始得分	完成 PS 预处理结果向 PL 推理核心的提交及结果返回
板载按键与显示接口	模式选择、确认、重新采集、返回及界面画面	实现板端交互和处理结果可视化
文件存储接口	图像、质量指标、推理结果、阈值和版本信息	在板端形成可核对、可导出的完整记录

表 2 系统主要接口

AXI4-Stream 接口使用帧起始和行结束信号维持像素坐标，利用有效—就绪握手机制保证模块间传输一致。视频处理模块工作在统一的 PL 视频时钟和复位域中，避免质量检测支路与主视频路径之间出现帧位置偏移。质量统计值在一幅图像处理完成后成组更新，PS 读取固定快照，防止一次判断混用不同图像的统计结果。

PS 侧以状态机管理质量检测、抓拍、预处理、推理和结果保存。PL 模块通过就绪、忙碌、完成和异常状态响应 PS 控制，只有输入数据准备完成且推理核心空闲时才允许启动新任务。该接口设计明确了视频流、控制流和推理数据的边界，也为后续分别优化质量门控、CNN 加速电路和 PS 端程序保留了相对独立的调整空间。

3. 关键模块设计与实现

3.1 视频采集与显示通路

视频采集与显示电路以 PYNQ-Z2 基础视频系统为基础，形成“HDMI 实时采集—像素格式转换—视频流分支—DDR 帧缓存—状态叠加—HDMI 显示输出”的处理通路。摄像头输入的视频一路经 VDMA 写入 DDR，用于实时显示、PS 侧抓拍和后续 CNN 推理；另一路直接送入质量门控电路，在像素传输过程中完成质量统计。显示端从 DDR 读取视频帧，并在输出前叠加取景框和质量状态。电路整体结构如图 2 所示，主要模块及功能如表 3 所示。

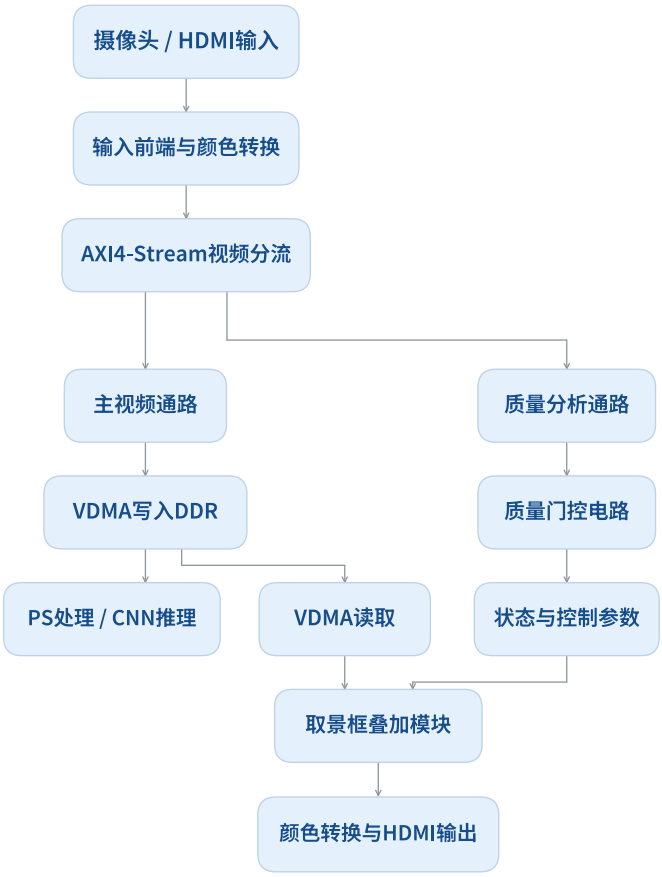


图 2 视频采集与显示电路结构框图

模块	主要功能	设计作用
HDMI 输入前端	接收摄像头画面并转换为 AXI4-Stream 视频流	建立实时图像输入通路
颜色转换与流水线缓冲	统一像素格式并改善模块间时序	为后续模块提供规范的视频流接口
AXI4-Stream Broadcaster	将像素流分为主视频通路和质量检测支路	使视频传输与质量统计并行运行
VDMA 与 DDR 帧缓存	完成视频流与 DDR 之间的数据搬运	为实时显示、PS 抓拍和推理提供统一图像来源
质量检测支路	向质量门控电路提供连续像素流	支持亮度、曝光和清晰度统计
取景框叠加模块	根据质量状态和坐标绘制彩色取景框	向操作者提供实时采集反馈
HDMI 输出前端	完成输出颜色转换和视频时序生成	在显示器上输出实时预览画面

表 3 视频采集与显示电路主要模块

3.1.1 720p HDMI 视频输入与颜色格式转换

系统采用 HDMI 摄像头作为图像输入设备，输入视频分辨率为 1280×720，帧率为 60 帧/s。摄像头输出的 HDMI 信号首先进入视频输入前端，由接收模块恢复像素时钟、同步信号和三通道像素数据，再转换为 24 位 AXI4-Stream 视频流。

AXI4-Stream 接口通过 TUSER 标记一帧图像的起始位置，通过 TLAST 标记一行图像的结束位置，并使用 TVALID 和 TREADY 完成有效数据握手。后续质量统计和取景框叠加模块根据这些信号恢复帧边界、行边界和当前像素坐标[11]。

输入像素流随后经过颜色转换模块和流寄存模块。颜色转换模块统一视频链路中的像素格式，流寄存模块用于改善模块间的时序连接。为确认摄像头、PL 视频链路与 PS 图像数组之间的颜色对应关系，系统分别使用红色和蓝色画面进行测试。测试结果表明，PS 从 DDR 读取红色画面时通道 2 数值最大，读取蓝色画面时通道 0 数值最大，由此确定帧数组采用 B、G、R 顺序。软件在保存图像和生成 CNN 输入前完成相应的通道转换。

3.1.2 VDMA 与 DDR 帧缓存

完成格式转换的视频流经像素打包后进入 AXI VDMA。VDMA 写通道将输入视频帧连续写入 DDR 帧缓存，读通道从 DDR 中读取视频帧并送往 HDMI 输出链路。DDR 帧缓存将摄像头采集与显示输出分隔开，使输入和输出视频能够在各自时序下连续运行。

DDR 同时作为 PL 视频通路和 PS 控制程序之间的共享图像存储区域。实时预览过程中，VDMA 持续更新帧缓存；质量条件满足后，PS 从实际送达的帧数据中提取 640×360 检测区域，完成抓拍保存和 CNN 输入预处理。由此，实时显示、质量复核和模型推理使用同一视频来源，不需要由 PS 逐像素接收和转发连续视频流[12]。

3.1.3 主视频通路与质量检测支路并行设计

系统在输入颜色转换和流水线缓冲之后加入 AXI4-Stream Broadcaster，将同一 24 位像素流分为主视频通路和质量检测支路。主视频通路继续进入像素打包模块和 VDMA 写通道，保持原有的视频采集与显示功能；质量检测支路将连续像素送入质量门控电路，计算取景区域的平均亮度、暗像素比例、亮像素比例和 Sobel 清晰度。

两条通路使用相同的帧起始、行结束和数据握手信号，因此质量统计过程能够与当前输入画面保持对应。质量检测支路只读取像素数据，不修改主视频通路中的图像。每帧统计完成后，质量门控电路将亮度、清晰度、质量状态和连续合格数量写入状态寄存器，供 PS 读取并更新界面。

该结构使质量检测在视频采集过程中同步完成，无需先将完整视频帧搬运至 PS 后再进行逐像素计算。主视频通路继续负责 DDR 写入和实时显示，质量检测支路承担像素级统计，两者在 PL 侧并行运行。

3.1.4 质量状态取景框叠加与 HDMI 输出

显示端由 VDMA 从 DDR 读取视频帧，经像素格式恢复和流寄存后送入取景框叠加模块。该模块根据 AXI4-Stream 中的帧起始和行结束信号维护横纵坐标，并且只在像素完成有效握手时更新坐标，避免下游暂停接收时发生取景框位置偏移。

取景框模块接收显示使能、质量状态、边界坐标和线宽等控制参数。当当前像素位于取景框边界范围内时，模块以设定颜色替换该位置的输出像素，其他区域保持原始画面。红色取景框表示当前图像未通过质量检测；黄色表示当前图像合格，但连续合格数量尚未达到抓拍要求；绿色表示 PL 侧已经连续三帧判定合格，系统进入抓拍复核阶段。

取景框叠加模块位于 VDMA 读出之后、HDMI 输出颜色转换之前，因此彩色状态框只作用于显示画面，不会写入 DDR 中的原始视频帧，也不会进入质量检测和 CNN 推理使用的抓拍图像。叠加后的像素流经过输出颜色转换和

HDMI 发送模块显示在外接显示器上，操作者可依据取景框状态和界面文字调整拍摄位置及光照条件。

3.1.5 视频通路板级实现结果

视频通路在 Vivado 2025.2 中完成设计、综合、实现和比特流生成，并在 PYNQ-Z2 板卡上进行验证。连接 HDMI 摄像头和显示器后，系统能够持续采集并输出 1280×720、60 帧/s 的实时画面。连续运行 10 分钟期间未出现黑屏、闪烁或画面冻结，验证了 HDMI 输入、VDMA 帧缓存和 HDMI 输出链路的稳定性。

红色和蓝色画面测试确认了 PS 侧帧数组的通道顺序，实际输出颜色与摄像头输入画面一致。加入 AXI4-Stream 分流模块和质量检测支路后，主视频通路仍能保持连续显示；加入取景框叠加模块后，显示画面能够根据质量状态切换红、黄、绿三种边框，DDR 中的抓拍图像不包含状态框。

板级测试表明，视频输入、DDR 帧缓存、质量检测分支和显示叠加能够在同一视频链路中协同运行，为后续图像质量门控、自动抓拍和 CNN 推理提供了稳定的视频输入。整机接入 CNN 推理和 PS 端交互程序后的综合运行效果与实物照片将在第五章统一展示。

3.2 图像质量门控与自动抓拍

图像质量门控模块用于在 CNN 推理前判断当前画面是否满足采集要求。模块接收视频分支输出的 24 位像素流，对中央 640×360 检测区域逐像素计算亮度、暗像素比例、亮像素比例和 Sobel 清晰度，并在一帧结束时输出本帧质量状态。模块完成 PL 侧流式质量统计，并与 PS 侧抓拍复核共同筛选后续推理图像。

质量门控电路由检测区域选择、亮度计算、曝光统计、Sobel 梯度计算、帧级判定、连续合格计数和控制状态接口组成。其结构如图 3 所示。

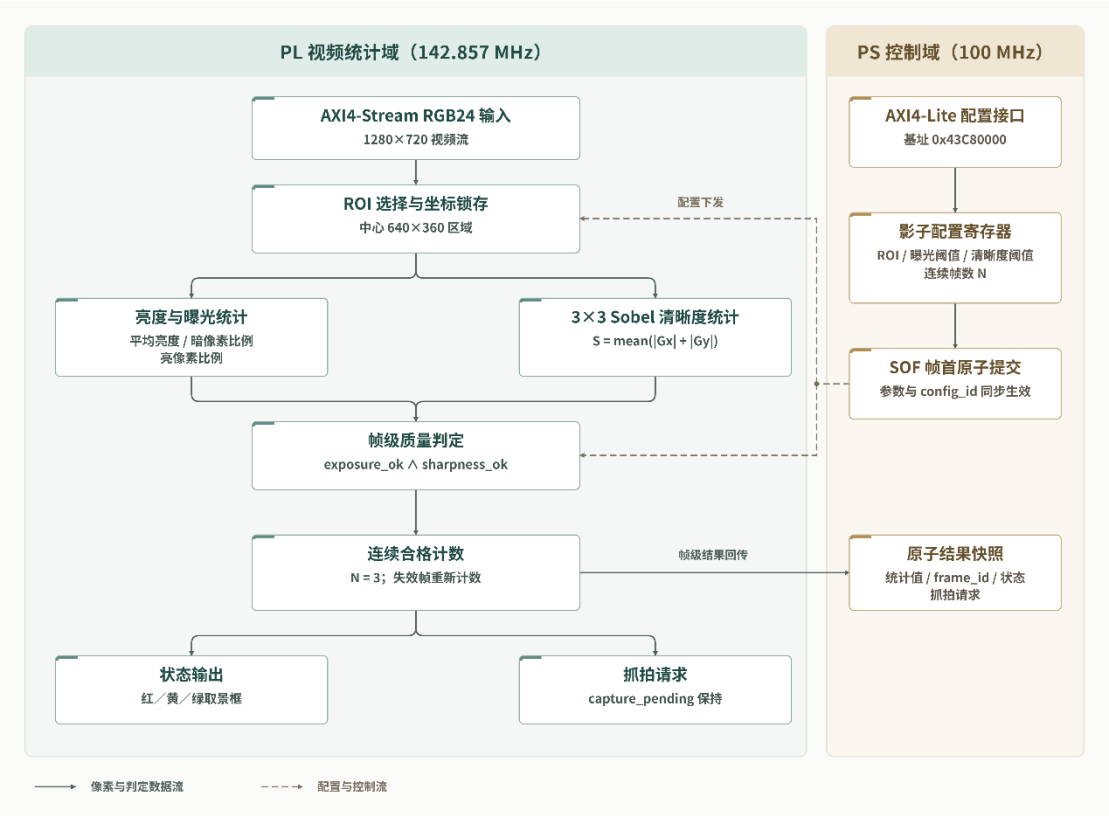


图 3 图像质量门控电路结构图

3.2.1 中心检测区域与亮度计算

输入视频分辨率为 1280×720。为了使质量检测区域与屏幕中的取景框保持一致，同时减少画面边缘背景对统计结果的影响，系统选取坐标起点为（320，180）、大小为 640×360 的中央区域作为检测区域。PL 侧根据 AXI4-Stream 帧起始和行结束信号维护当前像素坐标，只有像素位于该区域内时，才参与后续亮度、曝光和清晰度计算。

亮度采用整数加权方式由 RGB 三通道计算[13]：

$$Y = （77R + 150G + 29B + 128） >> 8$$

其中，R、G、B 分别表示当前像素的三个颜色分量，“>> 8”表示右移 8 位。该表达式近似实现 0.299R、0.587G 和 0.114B 的加权组合，能够在不使用浮点运算和除法器的情况下得到 8 位亮度值。检测区域内共有：

$$N_{ROI} = 640 \times 360 = 230400$$

个亮度像素。PL 在像素流传输过程中累计亮度总和，一帧结束后计算区域平均亮度，用于判断画面的整体曝光水平。

3.2.2 曝光质量检测

仅使用平均亮度容易掩盖局部曝光异常。例如，画面整体均值处于正常范围时，仍可能存在较大面积阴影或高亮反光。系统在计算平均亮度的同时，分别统计暗像素和亮像素数量。

暗像素定义为亮度值小于 16 的像素，亮像素定义为亮度值大于 239 的像素。对应比例为：

$$r_{dark} = \frac{N（Y < 16）}{N_{ROI}}$$

$$r_{bright} = \frac{N（Y > 239）}{N_{ROI}}$$

本系统要求平均亮度处于 40～210 之间，暗像素比例不超过 5%，亮像素比例不超过 2%。三个条件同时满足时，当前图像才通过曝光检测。平均亮度用于限制整体过暗或过亮，暗、亮像素比例用于识别局部阴影和高光区域，使曝光判定能够同时反映画面的整体水平和亮度分布。

最终采用 5%的暗像素比例上限，是考虑到真实皮肤画面中可能同时存在纹理、阴影和背景边缘。在已完成的真实采集测试中，画面清晰且整体亮度正常时，暗像素比例可达到约 4%，因此设置 5%的上限能够保留合理局部阴影，同时继续通过平均亮度条件排除明显过暗画面。亮像素比例上限设为 2%，用于限制局部高亮区域在检测区域中所占的范围。

3.2.3 Sobel 清晰度检测

系统采用 3×3 Sobel 算子评价图像中的边缘和纹理强度。PL 侧利用行缓冲和移位寄存器构建 3×3 滑动窗口，对检测区域内除边界外的像素计算水平梯度和垂直梯度：

$$G_x = -p_{00} + p_{02} - 2p_{10} + 2p_{12} - p_{20} + p_{22}$$

$$G_y = p_{00} + 2p_{01} + p_{02} - p_{20} - 2p_{21} - p_{22}$$

其中，p_{00}～p_{22}表示 3×3 窗口中的九个亮度像素。为减少硬件运算量，梯度幅值采用绝对值之和近似：

$$G = |G_x| + |G_y|$$

PL 对一帧检测区域内的有效梯度进行累加，有效梯度窗口数量为：

$$N_{\text{gradient}} = （640 - 2）\times（360 - 2）= 228404$$

Sobel 清晰度定义为：

$$S = \frac{G_{\text{sum}}}{\text{N}_{\text{gradient}}}$$

当前系统将 S≥20 作为清晰度通过条件。硬件实际判定时不直接执行除法，而是比较：

$$G_{sum} \geq 20 \times N_{\text{gradient}}$$

从而减少除法运算带来的硬件开销。Sobel 清晰度反映画面中边缘和纹理的总体强度，其数值不表示概率或百分比。当前阈值根据真实清晰画面和数字低通退化图像的响应差异确定，用于识别明显缺少边缘细节的输入。

3.2.4 连续合格判定、抓拍复核与单张保存

每帧图像需要同时满足平均亮度、暗像素比例、亮像素比例和 Sobel 清晰度要求，才被判定为本帧合格。PL 侧设置连续合格计数器：当前帧合格时计数加 1，任一条件不满足时计数清零。当连续合格数量达到 3 时，质量门控模块保持抓拍请求，并将当前质量状态更新为可抓拍状态。

连续三幅合格用于确认当前采集状态已经稳定，减少瞬时光照变化、摄像头抖动或单帧统计波动造成的误触发。显示端根据判定状态实时更新取景框：红色表示当前帧未通过，黄色表示当前帧通过但连续数量不足，绿色表示已经

满足抓拍条件。

PL 发出抓拍请求后，PS 侧从 VDMA 帧缓存中复制未叠加状态框的 640×360 原始图像。由于 PL 统计结果与 PS 实际取得的 DDR 图像之间存在数据传输和缓冲差异，PS 不会直接将硬件请求等同于抓拍图像已经合格，而是对实际取得的图像重新计算亮度、暗亮像素比例和 Sobel 清晰度。实际送达的图像连续三次通过相同规则后，系统保存最后一幅图像，并记录质量指标、配置编号和图像校验值。

单帧推理模式完成一次上述合格抓拍后进入 CNN 推理；三帧融合模式则独立完成三次合格抓拍和三次推理。质量门控中的“连续三幅合格”用于确认每次抓拍的图像质量，不同于三帧融合所使用的三幅推理图像。质量判定与抓拍复核流程如图 4 所示。

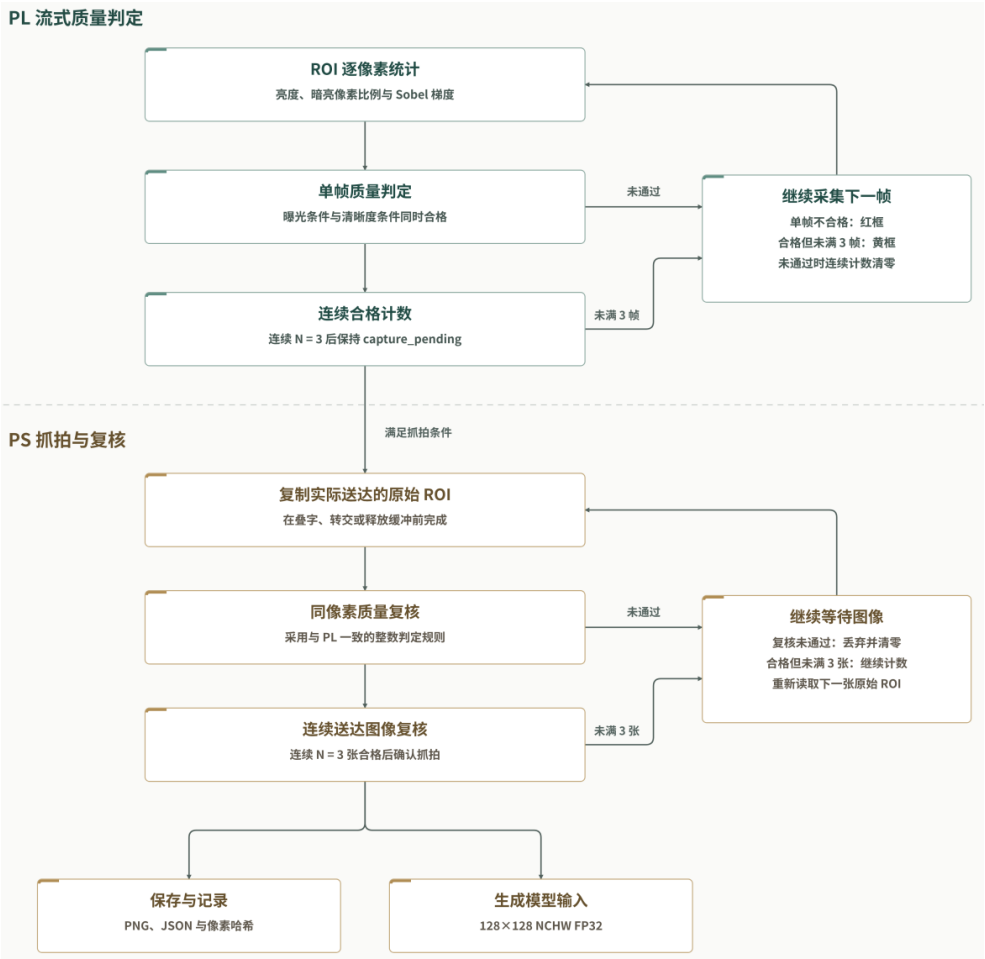


图 4 质量判定与抓拍复核流程图

3.2.5 参数配置与帧级同步控制

质量门控 IP 通过 AXI4-Lite 接口与 PS 通信，基地址为 0x43C80000，地址空间为 4 KiB。PS 可配置检测区域坐标、亮度范围、暗亮像素阈值、Sobel 清晰度阈值和连续合格数量，并读取当前帧编号、配置编号、质量统计值、判定状态和抓拍请求。

为防止 PS 在一帧处理过程中修改参数，配置数据先写入影子寄存器，再在下一帧起始位置统一生效。每次配置提交均对应独立的配置编号，PS 只读取与当前配置编号匹配的新结果，避免将旧配置产生的统计数据用于当前判断。

PL 侧在一帧统计完成后，将亮度、像素比例、清晰度、帧编号和质量状态同时写入结果寄存器。PS 读取前先触发结果快照，使一组数据在读取过程中保持不变，并在读取前后检查结果序号，避免混合不同帧的统计值。视频统计电路工作在约 142.857 MHz 时钟域，AXI4-Lite 控制接口工作在 100 MHz 时钟域，配置和结果通过跨时钟域同步逻辑传递。

当前质量门控运行配置见表 4。

参数	最终配置	判定作用
视频尺寸	1280×720	质量门控输入视频规格
检测区域	x=320，y=180，640×360	与中央取景框对应
平均亮度	40～210，包含边界	排除整体过暗或过亮画面
暗像素比例	Y<16，比例≤5%	限制大面积阴影和暗区
亮像素比例	Y>239，比例≤2%	限制局部高光和过亮区域
Sobel 清晰度	S≥20	排除明显缺少边缘细节的图像
连续合格数量	N=3	确认采集状态稳定后触发抓拍

表 4 图像质量门控最终运行配置

3.2.6 阈值选取依据与板级验证结果

质量门控阈值结合检测指标的物理含义、真实皮肤画面响应和数字退化测试确定。平均亮度与暗亮像素比例共同评价曝光状态，避免单一均值掩盖局部

异常；Sobel 阈值用于区分当前清晰画面与明显低通退化画面；连续三幅合格机制则在采集稳定性和操作响应速度之间取得平衡。上述配置为当前整机版本实际加载的参数，后续推理与结果保存均使用同一配置。

板级验证中，PL 质量统计结果的平均发布速率约为 60.005 帧/s，与 720p60 视频输入速率一致，能够连续处理输入像素流。采用最终配置后，真实皮肤场景获得 137 份连续稳定通过的状态快照；数字偏暗输入的 34 份稳定状态均因平均亮度低于 40 被拒绝；数字低通输入的 92 份稳定状态均因 Sobel 清晰度不足被拒绝。

自动抓拍测试在 14.153 s 的有限任务时长内取得 640×360 三通道原始图像。对保存图像重新计算亮度、暗亮像素比例、Sobel 清晰度和质量标志，并核对图像哈希及记录文件，16 项检查均通过。当前优化后的 PS 同像素质量复核在 100 次正式组件测试中的平均耗时为 153.969 ms/张。质量门控板级验证结果见表 5。

验证项目	**最终测试结果**	**验证结论**
PL 质量统计速率	约 60.005 帧/s	能够连续处理 720p60 输入视频
真实皮肤场景	137 份连续稳定通过快照	当前实际拍摄场景能够正常放行
数字偏暗输入	34/34 因平均亮度不足被拒绝	过暗检测响应正确
数字低通输入	92/92 因 Sobel 清晰度不足被拒绝	低清晰度检测响应正确
PS 质量复核	平均 153.969 ms/张	实际取得图像能够按同一规则复核
自动抓拍与保存	14.153 s 内完成抓拍，16 项核验通过	保存图像、质量指标和记录文件一致

表 5 图像质量门控板级验证结果

验证结果表明，质量门控模块能够在实时视频传输过程中完成曝光和清晰

度统计，并通过连续合格判定控制自动抓拍。PL 侧实时统计、PS 侧实际图像复核和结果保存共同形成质量筛选闭环，使进入 CNN 推理流程的图像满足当前设定的采集条件。

3.3 CNN 模型训练与量化部署

系统采用轻量 CNN 完成皮肤病变风险二分类。模型开发围绕低资源器件部署需求展开，在控制参数量和计算量的同时，统一训练、CPU 端量化模型及 PL 定点推理所使用的输入尺寸、颜色顺序、归一化参数和类别定义。模型输出“暂未提示明显风险”和“建议就医”两个类别对应的原始得分，由 PS 端进一步完成概率换算和阈值判定。

3.3.1 数据集划分与二分类任务定义

模型使用 PAD-UFES-20 数据集进行训练和测试[14]。数据集共包含 2295 幅图像，涉及 1373 名患者和 1889 个病灶。根据风险预筛后的处置需求，将基底细胞癌（BCC）、鳞状细胞癌（SCC）、黑色素瘤（MEL）和光化性角化病（ACK）归入“建议就医”类别，将色素痣（NEV）和脂溢性角化病（SEK）归入“暂未提示明显风险”类别。

为避免同一患者的不同图像同时进入训练集和测试集，数据划分以患者为单位进行，并检查不同数据子集之间的患者、病灶和图像交集。最终将数据划分为训练集、验证集和测试集，结果见表 6。训练集用于模型参数学习，验证集用于训练过程监控、模型选择和判定阈值确定，测试集用于比较浮点模型、量化模型和 PL 定点模型的最终性能。

数据子集	图像数量	患者数量	暂未提示明显风险	建议就医
训练集	1610	954	335	1275
验证集	342	223	82	260
测试集	343	196	61	282
合计	2295	1373	478	1817

表 6 数据集患者级划分结果

3.3.2 输入图像预处理

模型输入采用 128×128 RGB 图像。训练阶段首先将原始图像转换为 RGB 格式，再使用双线性插值直接缩放至 128×128 像素，不进行额外裁剪或填充。像素值缩放至 0～1 范围后，按照训练集统计得到的三通道均值和标准差进行归一化：

$$\mathrm{mean}_{\mathrm{RGB}} = [0.665570, 0.522759, 0.462534]$$

$$\mathrm{std}_{\mathrm{RGB}} = [0.140920, 0.140212, 0.146932]$$

$$\mathrm{x}_{\mathrm{norm}}(c) = \frac{\frac{\mathrm{x(c)}}{255.0} - \mathrm{mean}_{\mathrm{RGB}}(\mathrm{c})}{\mathrm{std}_{\mathrm{RGB}}\,(\mathrm{c})}$$

其中，c 依次表示 R、G、B 通道。归一化后的数据按照 NCHW 顺序排列，最终输入张量尺寸为 1×3×128×128。

板端运行时，PS 从质量复核合格的抓拍图像中生成模型输入，并执行与训练阶段一致的颜色转换、图像缩放和归一化操作，避免训练端与部署端预处理方式不同造成模型输出偏差。

3.3.3 轻量化 CNN 网络结构

针对 XC7Z020 的逻辑、DSP 和片上存储资源，模型采用顺序卷积结构。网络前端借鉴 ResNet18 的 Stem 设计，通过 7×7 步长卷积、批归一化、ReLU 激活和最大池化提取基础视觉特征[15]。随后依次设置 32 通道、64 通道和 128 通道的 3×3 卷积模块，并通过池化逐步降低特征图的空间尺寸。

最后一组卷积输出 8×8×128 特征图，全局平均池化将其压缩为 128 维特征向量，再由 128→2 的全连接层输出两个类别的原始得分。该结构保留标准卷积、池化和全连接等规则算子，便于在 PL 侧建立固定的数据通路和并行乘加结构。

模型参数总量为 120,834，单次推理计算量约为 66.85 MMAC。在保持二分类特征提取能力的同时，模型规模能够适配 PYNQ-Z2 所使用的 XC7Z020 器

件，为后续 INT8 定点化和硬件加速提供基础。

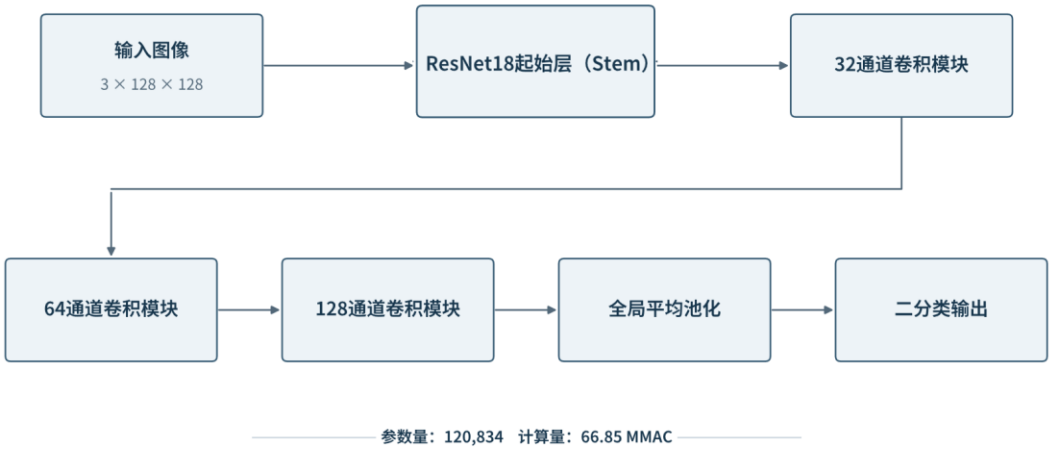


图 5 轻量 CNN 网络结构图

3.3.4 模型训练与模型选择

模型训练采用交叉熵损失函数，标签平滑系数设置为 0.05，批次大小为 64，初始学习率为 0.003，权重衰减系数为 0.0001，随机种子设置为 42[16]。针对 MEL 样本数量较少的问题，训练过程中对该类别实施 8 倍过采样，并结合有效样本数进行类别平衡，降低类别分布不均衡对模型学习的影响[17]。

模型最多训练 150 轮，并设置 30 轮早停机制。当验证集指标连续 30 轮未提升时结束训练。实际训练在第 101 轮停止，以验证集 macro-F1 作为模型选择依据，最优模型出现在第 71 轮。该模型作为后续量化、部署格式转换和 PL 定点实现的基础版本。

训练完成后，模型以固定批次大小 1 导出为 ONNX 格式（opset 17）。导出时将批归一化参数折叠至相邻卷积层，部署计算图由卷积、ReLU、最大池化、全局平均池化和全连接算子组成。模型权重、ONNX 文件、数据划分、预处理参数和预测结果均随版本归档，并保存 SHA256 校验值，确保训练、转换和部署使用同一模型版本。

3.3.5 INT8 量化与 PL 部署格式转换

模型量化分为 CPU 端量化模型和 PL 定点部署两条路径。CPU 侧首先将

FP32 模型转换为 ncnn 格式，并从训练集中选取 298 幅图像作为量化校准集，确保校准集与验证集、测试集无交叉。

量化阶段分别生成 KL 散度、ACIQ 和均衡化量化（EQ）三种 INT8 候选模型，并保留 ncnn FP32 模型作为数值参考。各候选模型采用相同的数据划分、输入预处理和类别顺序进行测试。综合测试集分类性能、模型存储量和板端运行表现，最终将 KL INT8 作为 CPU 侧实际使用的量化模型，EQ INT8 作为量化优化对照，FP32 模型用于检查转换前后的数值变化[18]。

由于量化会改变模型原始得分的数值分布，不同模型分别在验证集上确定温度系数和建议就医判定阈值。最终保留模型的参数见表 7。推理时先利用温度系数缩放两个原始得分，再通过 Softmax 计算建议就医概率，并与相应阈值进行比较[19]。

模型	温度系数 T	建议就医阈值
ncnn FP32	0.883238	0.709830
KL INT8	0.890488	0.697674
EQ INT8	0.876223	0.721251

表 7 ncnn 候选模型的温度系数与判定阈值

表 7 中的温度系数和判定阈值分别针对 CPU 端 ncnn 候选模型的输出分布确定。PL 定点部署不直接沿用 ncnn 模型的工作点，而采用项目冻结的温度系数 0.883517 和判定阈值 0.709762。ncnn INT8 模型在软件接口外部仍接收归一化后的 float32 数据，由运行库在模型内部完成定点转换。PL 部署则依据硬件接口重新确定数据格式，不直接使用 ncnn 内部量化尺度。PS 将归一化结果按照 1/16 的量化步长转换为 8 位有符号定点数据，PL 侧使用 8 位权重和激活值完成卷积计算，并为乘加运算配置更宽的中间累加位宽；最终两个原始得分按照 1/32 的量化步长恢复为数值结果。

CPU 和 PL 两条路径使用相同的输入尺寸、RGB 顺序、归一化参数、类别顺序和判定含义。通过软件定点参考、仿真输出和板端结果逐级比对，确保模型从训练框架转换至硬件实现后仍保持一致的输入输出关系。

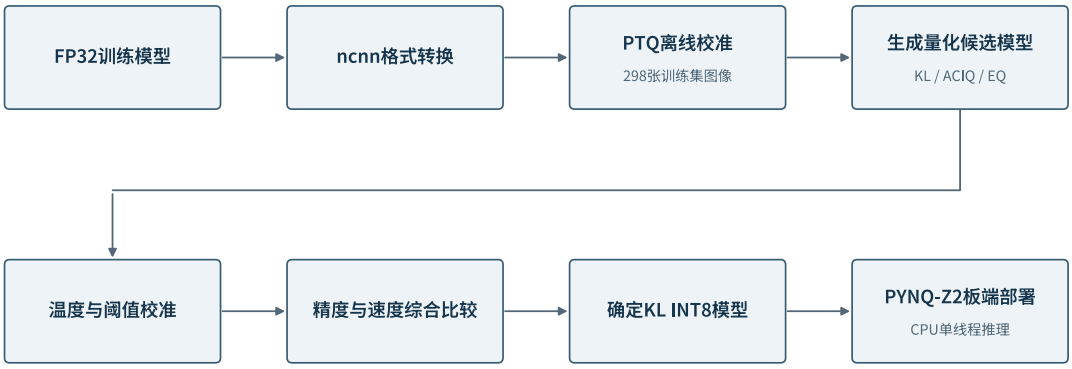


图 6 模型量化与部署流程图

3.3.6 测试集性能与模型存储开销

FP32 模型在默认 0.5 阈值下，测试集 AUC 为 0.915824，建议就医类别召回率为 0.929078，特异度为 0.704918，平衡准确率为 0.816998，macro-F1 为 0.812966。

考虑到风险预筛需要兼顾建议就医类别的检出能力和误报情况，ncnn FP32 模型在验证集上以建议就医召回率达到 0.90 为目标确定工作点，判定阈值为 0.709830。在该工作点下，FP32 模型在测试集上的建议就医召回率为 0.875887，特异度为 0.803279，平衡准确率为 0.839583。

ncnn FP32 及三种 INT8 候选模型在同一测试集上的性能见表 8。各模型均使用与自身输出分布匹配的温度系数和判定阈值。

模型	AUC ↑	建议就医召回率 ↑	特异度 ↑	平衡准确率 ↑	macro-F1 ↑
ncnn FP32	0.915998	0.875887	0.803279	0.839583	0.794493
KL INT8	0.911406	0.879433	0.803279	0.841356	0.797842
EQ INT8	0.915242	0.875887	0.803279	0.839583	0.794493
ACIQ INT8	0.901697	**0.886525**	0.786885	0.836705	0.799141
PL INT8（最终部署）	**0.9238**	**0.8830**	**0.8033**	**0.8431**	**0.8012**

表 8 测试集模型性能对比

在 343 幅测试图像的完整推理测试中，ncnn FP32、KL INT8 和 EQ INT8 的总体准确率分别为 86.30%、86.59%和 86.30%。KL INT8 的平衡准确率和 macro-F1 分别达到 0.841356 和 0.797842，在模型规模明显缩小的情况下保持了与 FP32 接近的分类性能，因此选为 CPU 侧主要量化模型。EQ INT8 的 AUC 最接近 FP32 模型，作为量化优化对照保留；ACIQ INT8 虽然取得较高的建议就医召回率，但特异度和 AUC 相对较低。

按原始病种统计，KL INT8 对 ACK、BCC 和 SCC 的建议就医召回率分别为 89.34%、90.48%和 86.36%。MEL 在测试集中仅包含 12 幅图像、涉及 8 名患者，对应召回率为 50.00%，后续模型迭代需要进一步增加该类别的数据覆盖。

PL 最终定点模型在同一 343 幅测试图像上完成逐样本推理，混淆矩阵为[[49，12]，[33，249]]，总体准确率为 86.88%，建议就医召回率为 88.30%，特异度为 80.33%，平衡准确率为 84.31%，macro-F1 为 80.12%，AUC 为 92.38%。该结果说明，面向 PL 实现重新确定定点格式后，模型仍保持了当前二分类任务的主要性能。

FP32 权重文件大小为 482,204 字节，INT8 权重文件大小为 122,616 字节，权重存储量减少约 74.57%。模型量化显著降低了权重存储和数据传输开销，为在 XC7Z020 上使用片上存储保存主要权重、减少外部存储访问提供了条件。

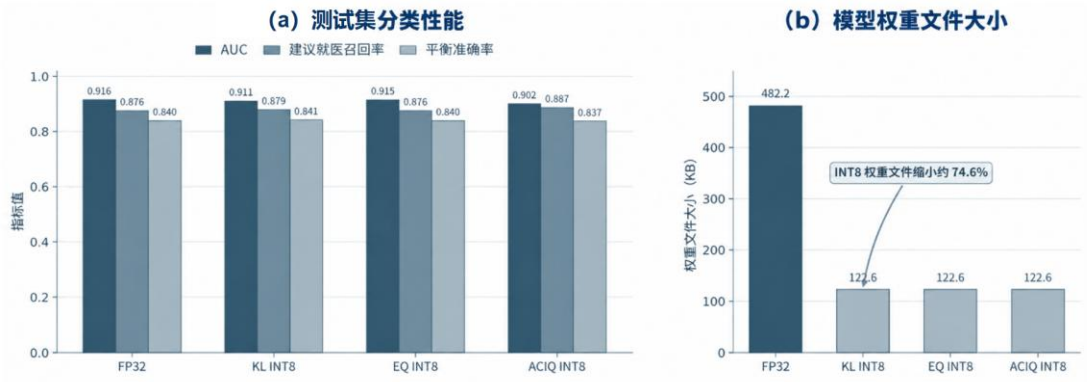


图 7 模型量化性能与权重文件大小对比图

3.4 CNN 推理加速电路

CNN 推理加速电路负责在 PL 侧执行轻量 CNN 的卷积、池化、全局平均池化和全连接运算。该电路接收 3.3 节所述模型和定点参数，不改变网络拓扑、训练权重及二分类输出顺序，并通过定点运算、片上存储和通道并行提高卷积计算效率。系统采用事件触发方式工作，每次取得符合质量条件的图像后启动一次推理，不对实时视频逐帧执行 CNN。

PS 侧将 128×128 RGB 图像完成归一化和定点打包，再通过独立 DMA 和 AXI 高性能端口送入 CNN 加速电路。PL 侧依次完成四层卷积及其池化、全局平均池化和全连接运算，最终输出负类和正类两个原始得分。PS 读取原始得分后完成数值恢复、概率计算和阈值判定，并将结果交给界面显示与文件保存程序。视频通路使用 HP0 端口，CNN 输入输出使用独立的 HP1 端口，使视频帧传输和推理数据搬运能够在同一系统中分别组织。

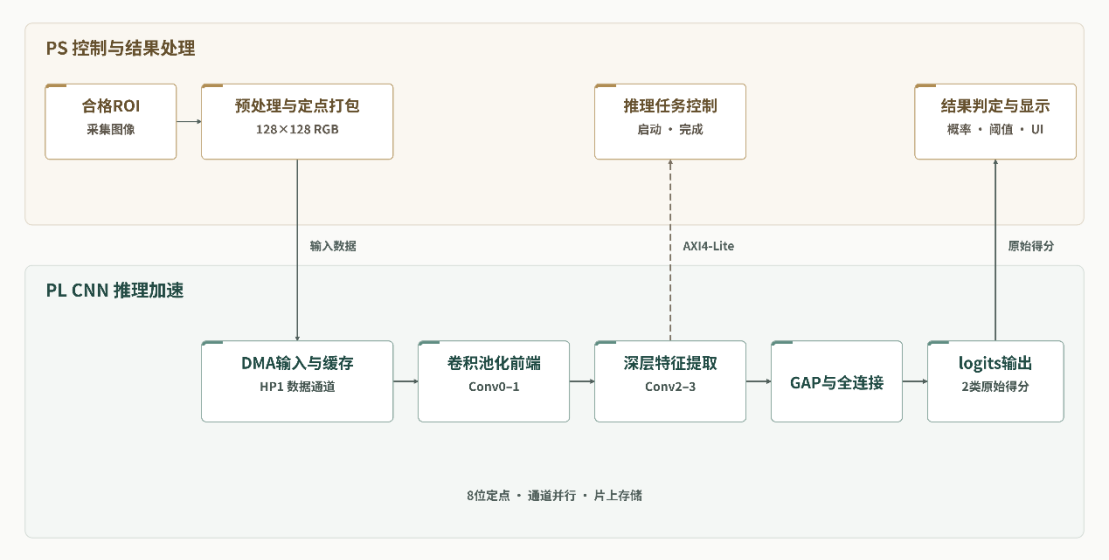


图 8 CNN 推理加速电路总体结构图

3.4.1 加速电路架构与网络映射

加速电路按照轻量 CNN 的计算顺序建立流式数据通路。输入图像首先进入 7×7 步长卷积和最大池化模块，随后依次经过三组 3×3 卷积与池化运算，得到 8×8×128 特征图；全局平均池化将空间特征压缩为 128 维向量，最终由全连

接层输出两个类别的原始得分。卷积层内部完成乘加、偏置叠加、定点缩放、饱和处理和 ReLU 激活，池化模块直接消费前级输出，避免频繁将中间特征图写回 DDR。

电路采用“层内并行、层间顺序衔接”的实现方式。每一卷积层通过多路乘加单元并行计算多个输出通道，不同层之间则按照网络拓扑传递特征数据。该结构能够控制瞬时资源占用，使完整网络适配 XC7Z020 的逻辑、DSP 和片上存储资源，同时保持模型原有的计算关系。

卷积、池化、全局平均池化和全连接模块采用统一的数据握手方式。只有当前级输出有效且下一级能够接收时，数据才向后传递；下游暂停时，当前数据和控制状态保持不变。帧内计算完成后，电路产生完成信号并输出一组二分类结果，随后返回空闲状态，等待下一次推理任务。

3.4.2 定点计算、片上存储与并行调度

模型权重和主要激活值采用 8 位有符号定点数表示，不同层根据自身数值范围使用对应的小数位配置。输入定点数据的量化步长为 1/16，输出原始得分的量化步长为 1/32。乘加过程中使用更宽的中间累加位宽，卷积结果在进入下一层前执行半步取偶、饱和截断和 ReLU 激活，避免直接使用 8 位累加造成溢出。全局平均池化同样保留足够的累加位宽，再转换为全连接层需要的定点格式。

网络权重存放在 PL 片上 ROM 或 BRAM 中，卷积计算采用循环行缓存和滑动窗口读取相邻像素。中间特征以分组数据流在模块间传递，每个 64 位数据单元承载 8 个 8 位通道，减少全通道宽向量带来的布线压力。首层卷积计算量最大，配置 16 路输出通道并行计算，并拆分为两个 8 通道数据包向后传输；后续卷积层采用 8 路通道并行，在计算速度和器件资源之间取得平衡。

各卷积层根据输入尺寸、通道数量和卷积核大小独立维护地址、窗口和通道计数状态。卷积结果生成后直接进入池化或下一层缓存，全局平均池化按通道组累加空间数据，全连接层直接读取 128 维汇总结果。整个推理过程不需要 PS 逐层参与，也不需要将各层中间特征反复搬运至 DDR，从而减少软件调用

和外部存储访问。

3.4.3 PS/PL 接口与推理任务控制

CNN 加速电路工作在 80 MHz 时钟域，通过 AXI4-Lite 接口接收 PS 侧的启动命令并返回空闲、运行和完成状态。输入输出数据由独立 DMA 搬运，DMA 连接 Zynq PS 侧 HP1 高性能端口，与视频 VDMA 使用的 HP0 端口分离。

每次推理输入包含 128×128 个像素。PS 将每个像素的 R、G、B 三个 8 位定点分量依次放入 32 位数据的低 24 位，高 8 位置零，共形成 16384 个 32 位输入数据。推理完成后，电路输出一个 32 位结果，其中低 16 位分别保存负类和正类两个 8 位原始得分。PS 将其解释为有符号数并按 1/32 恢复数值，随后使用冻结的温度参数和判定阈值生成风险提示。

接口或模块	当前配置	主要作用
CNN 控制接口	AXI4-Lite，基地址 0x43C90000	配置并启动推理任务，读取运行状态
CNN DMA 接口	AXI4-Lite，基地址 0x40400000	完成输入和输出数据搬运
输入数据	16384 个 32 位数据，共 65536 B	低 24 位依次保存 R、G、B 定点分量
输出数据	1 个 32 位数据	低 16 位保存两个 8 位原始得分
数据端口	PS HP1，32 位	连接 DDR 与 CNN DMA
CNN 核心时钟	80 MHz	驱动推理计算和内部数据流

表 9 加速电路主要接口和数据格式

PS 只有在输入数据准备完成且 CNN 核心处于空闲状态时才发出启动命令。任务启动后，PL 独立完成整网计算；完成信号产生后，PS 读取并核对输出数据，再释放本次任务使用的缓冲区。该控制方式将复杂的界面和流程判断保留在 PS 侧，将结构固定、乘加密集的网络计算交由 PL 执行。

3.4.4 实现结果与数值一致性验证

最终 CNN 独立计算核在 80 MHz 条件下完成综合、布局布线和时序收敛，占用 4206 个 LUT、4030 个触发器、54.5 个 BRAM Tile 和 40 个 DSP，建立时间裕量为+1.251 ns，保持时间裕量为+0.009 ns。CNN 与视频通路、质量门控、DMA 及 PS 接口集成后，完整系统占用 22181 个 LUT、33855 个触发器、71.5 个 BRAM Tile 和 70 个 DSP，分别占器件可用资源的 41.69%、31.82%、51.07% 和 31.82%。完整系统布线后的建立时间裕量为+0.099 ns，保持时间裕量为 +0.014 ns，建立时间、保持时间和脉冲宽度检查均无失败端点，满足既定时序约束。

实现范围	LUT	FF	BRAM Tile	DSP	时序结果
Round42 CNN 计算链及 AXI 包装	4206	4030	54.5	40	80 MHz，WNS +1.251 ns，WHS +0.009 ns
Round42 完整系统	**22181**	**33855**	**71.5**	**70**	**WNS +0.099 ns，WHS +0.014 ns**

表 10 加速电路资源与时序结果

板端测试中，CNN 硬件事务平均耗时为 48.864 ms，P95（95 分位耗时）耗时为 48.867 ms；包含启动、输出读取和结果检查的内部调用平均耗时为 49.818 ms。以标准化 FP32 输入为起点，计入定点转换、数据打包、DMA 传输和输出检查后，完整 PL 推理调用平均耗时为 69.498 ms，P95 耗时为 70.476 ms。上述时间不包含图像解码、缩放、归一化、界面刷新和文件保存。

计时范围	平均耗时/ms	P95 耗时/ms
CNN 硬件事务	48.864	48.867
启动至输出检查完成	49.818	50.258
标准化 FP32 输入至原始得分输出	69.498	70.476

表 11 不同计时范围下的板端耗时

数值正确性按照软件定点参考、C 仿真、有限深度 FIFO 的 RTL 仿真、板端固定输入和测试集推理逐级验证。连续四组固定输入在帧间不复位的情况下均得到预期结果，下游暂停接收时输出数据能够保持稳定。343 张测试集的 PL 输出与冻结软件定点参考在原始编码、恢复得分、概率和阈值判定上保持一致，说明硬件实现正确复现了当前定点模型。模型的分类性能见 3.3.6 节，PL 与 ARM 基线的统一入口性能对比及加速电路迭代过程在第四章进一步说明。

3.5 PS 端控制与交互程序

PS 端控制与交互程序负责连接视频预览、质量门控、CNN 推理、结果显示和文件保存。程序通过板载按键接收操作者指令，根据当前页面控制质量检测、图像抓拍和推理任务，并将 PL 侧返回的质量指标与模型输出转换为直观的界面信息。

3.5.1 菜单模式、按钮交互与系统状态控制

程序启动后进入主菜单，提供正常模式、三帧融合推理和导出结果三个选项。操作者使用 KEY0 和 KEY1 切换选项，按 KEY2 确认。正常模式在图像质量连续合格后选择最后一张图像执行一次 CNN 推理；三帧融合推理保留三张质量合格图像，分别执行推理后融合结果；导出结果用于核对并整理已经保存的图像和对应记录。

程序按照“主菜单—实时预览—质量检测—图像抓拍—模型推理—结果显示”的顺序切换页面。每次进入采集页面时，PS 端重新配置质量门参数并清除上一轮的连续合格计数和抓拍标志，防止上一轮状态影响新的采集任务。

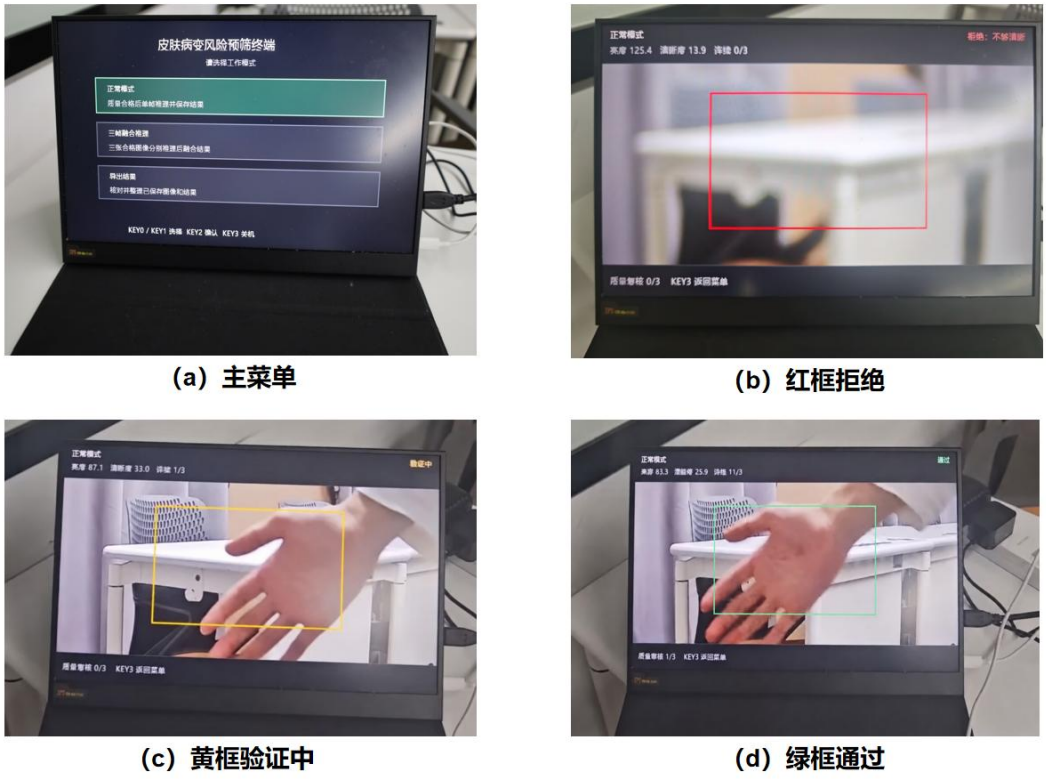


图 9 PS 端主菜单与实时质量检测界面

3.5.2 实时预览与质量状态显示

进入采集页面后，系统持续显示摄像头画面，并在画面中叠加中央检测框。PL 侧完成检测框的像素级绘制，PS 端读取质量门输出的亮度、清晰度、连续合格帧数和拒绝原因，在界面顶部显示当前检测结果。

检测框颜色随质量状态变化：当前图像曝光或清晰度不合格时显示红色；单帧已经合格但连续合格数量尚未达到 3 帧时显示黄色；连续 3 帧均满足要求并产生抓拍请求时显示绿色。界面同时给出“暗区过多”“亮区过多”或“清晰度不足”等提示，便于操作者根据具体原因调整拍摄距离、角度和环境光照。

3.5.3 自动抓拍与 CNN 输入生成

PS 端接收到 PL 侧抓拍请求后，从视频缓冲区取得未叠加取景框和文字信息的原始图像，并调用第 3.2 节所述复核流程确认实际取得的图像满足质量要求。正常模式保存连续合格图像中的最后一张；三帧融合模式依次保留三张复

核合格图像。

每张合格图像截取 640×360 检测区域，采用双线性插值缩放至 128×128，并按照模型训练阶段确定的 RGB 通道顺序、均值和标准差完成归一化。随后，程序将数据排列为 1×3×128×128 的 NCHW 格式，按照 PL 端输入格式打包并启动 CNN 推理任务。推理完成后，PS 端读取两个类别的输出值，计算模型风险概率并进入结果显示页面。

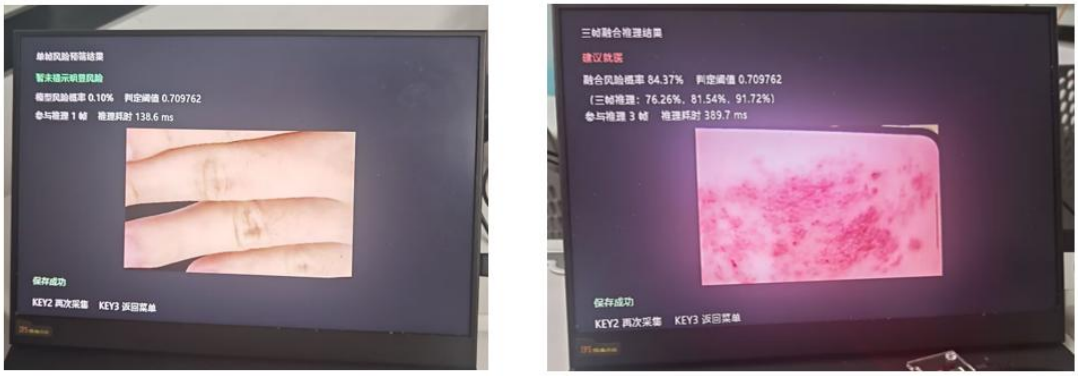
3.5.4 单帧推理、三帧融合与风险结果显示

两种推理模式的处理方式见表 12。正常模式只对一张合格图像执行推理，适合快速完成一次风险预筛。三帧融合模式对三张合格图像分别执行推理，再对两个类别的三组输出值分别求算术平均，经过温度参数校正后计算融合风险概率。该模式融合的是三次模型输出，不是对三张图像或三个概率直接求平均。

模式	参与推理的图像	推理次数	结果生成方法	界面显示内容
正常模式	1 张	1 次	根据单次模型输出完成判定	风险提示、模型风险概率、判定阈值、推理耗时
三帧融合推理	3 张	3 次	对三组两类别输出分别求平均后完成判定	三次风险概率、融合风险概率、判定阈值、总推理耗时

表 12 PS 端两种风险预筛模式的处理方式

系统采用 0.709762 作为最终判定阈值。当风险概率达到或超过该阈值时，界面显示“建议就医”；低于该阈值时显示“暂未提示明显风险”。结果页面同时显示实际参与推理的图像、模型风险概率、判定阈值、参与推理帧数和推理耗时。三帧融合模式额外显示三次独立推理的风险概率，使操作者能够查看各帧输出及其融合结果。输入图像、单帧输出、融合过程和判定阈值共同构成可追溯的结果说明。



（a）单帧“暂未提示明显风险”　　（b）三帧融合“建议就医”

图 10 单帧推理与三帧融合结果界面

3.5.5 结果自动保存与可选导出

每次推理结束后，系统自动将本次图像和对应结果保存至板端存储空间。正常模式保存 1 张 640×360 RGB 图像，三帧融合模式保存 3 张图像，并同步记录质量指标、各帧模型输出、融合结果、判定阈值、模型版本、位流版本和推理耗时。图像采用 PNG 格式保存，结构化结果采用 JSON 和 CSV 格式记录。程序完成文件写入和完整性检查后，在结果页面显示“保存成功”；若图像或结果记录不完整，则提示保存失败。

主菜单中的“导出结果”用于统一核对和整理已经保存的采集记录。操作者选择该功能后，程序检查每组记录中的图像、质量指标和推理结果是否完整，将通过检查的记录整理为导出文件，并保留图像与结果之间的对应关系。正常模式和三帧融合模式采用相同的记录编号，三帧融合结果同时包含 3 张输入图像、3 次风险概率和最终融合结果，便于后续复核模型输入、判定过程及保存内容。

导出完成后，界面显示成功导出的记录数量和异常记录数量。本轮 PS 端功能测试共生成并导出 8 组结果，其中包括 6 组单帧推理结果和 2 组三帧融合结果，所有记录均通过完整性检查。导出文件保存在板端，可进一步复制到计算机进行结果统计、报告整理和展示，不上传至云端。

3.5.6 异常处理与下一次采集控制

当图像未通过质量检测时，程序保持在实时采集页面，不启动 CNN 推理，并继续显示不合格原因。若出现配置编号不一致、图像获取超时、推理输出异常或文件写入失败，程序取消当前任务并在界面提示相应状态，未完整保存的数据不会被标记为成功结果。

结果页面中，操作者可以按 KEY2 重新采集，或按 KEY3 返回主菜单。重新采集时，程序清除上一轮图像、连续计数和推理结果，重新进入质量检测流程；返回主菜单时，程序停止当前任务并释放视频缓冲区和推理资源。

最终版本完成的板级运行验证共执行 6 组正常模式任务和 2 组三帧融合任务，实际处理 12 张输入图像并完成 12 次 CNN 推理，8 组结果均完成保存。正常模式从质量复核完成到结果页首次显示的平均时间为 220.064 ms，三帧融合模式为 463.814 ms；运行期间未出现视频任务、CNN 任务、缓冲区或界面控制异常。

4. 工程优化过程

4.1 模型训练与量化优化

模型优化同时受到分类性能和板端资源两方面的限制。PAD-UFES-20 数据集中不同病变类别的样本数量差异较大，其中 MEL 样本较少；同时，XC7Z020 的片上存储和计算资源有限，模型结构还需要满足后续定点化和 PL 部署要求。因此，项目分别从训练方法、判定阈值和模型量化三个方面进行调整。

训练阶段按照患者划分训练集、验证集和测试集，避免同一患者的多张图像分散到不同数据子集中。针对 MEL 样本不足的问题，对该类别实施 8 倍过采样，并结合类别平衡减小样本数量差异的影响。训练中采用 0.05 的标签平滑系数，降低模型对训练样本的过度拟合；以验证集 macro-F1 选择模型，并设置连续 30 轮无提升后停止训练。模型在第 71 轮取得最佳验证结果，训练于第

101 轮停止，避免继续训练造成性能下降和计算资源浪费。

模型最初使用 0.5 作为二分类判定阈值，但该设置下测试集特异度仅为 70.49%，对“建议就医”的判断偏多。项目根据验证集结果重新确定判定阈值，将 ncnn FP32 模型的阈值调整为 0.709830。调整后，测试集特异度由 70.49%提高至 80.33%，平衡准确率由 81.70%提高至 83.96%；建议就医类别召回率由 92.91%调整为 87.59%。该调整降低了误报比例，同时保留了较高的风险样本检出能力。

完成 FP32 模型训练后，项目采用训练后量化降低模型存储量和板端计算开销。量化校准集由训练集中的 298 幅图像组成，分别生成 KL、ACIQ 和 EQ 三种 INT8 候选模型。不同候选模型均重新使用验证集确定温度系数和判定阈值，再在同一测试集上比较分类性能。测试结果表明，KL INT8 在总体准确率、平衡准确率、macro-F1、模型大小和板端推理时间之间表现较为均衡，因此选为 CPU 端实际使用的量化模型；EQ INT8 保留用于不同量化方法的比较，ACIQ INT8 未作为最终方案。

量化前后的主要变化见表 13。KL INT8 将权重文件由 482,204 字节减小至 122,616 字节，存储量降低 74.57%。在统一输入和计时范围下，PYNQ-Z2 ARM 端推理平均耗时由 92.900 ms 降低至 72.859 ms，减少 21.57%。量化后的测试集总体准确率和平衡准确率没有下降，AUC 仅降低 0.46 个百分点。

优化项目	优化前	优化后	变化
FP32 判定阈值	0.500000	**0.709830**	**+41.95%**
测试集特异度	70.49%	**80.33%**	**+9.84%**
测试集平衡准确率	81.70%	**83.96%**	**+2.26%**
权重文件大小	482,204 B	**122,616 B**	**-74.57%**
ARM 端平均推理耗时	92.900 ms	**72.859 ms**	**-21.57%**
测试集总体准确率	86.30%	**86.59%**	**+0.29%**
测试集平衡准确率	83.96%	**84.14%**	**+0.18%**
测试集 macro-F1	79.45%	**79.78%**	**+0.33%**
测试集 AUC	**91.60%**	91.14%	**-0.46%**

表 13 模型判定阈值与 INT8 量化优化前后对比

CPU 端 KL INT8 模型和 PL 端定点模型采用不同的量化方式。PL 端没有直接使用 ncnn 模型内部的量化尺度，而是根据硬件输入、权重、激活和累加位宽重新确定定点格式，并通过软件参考、仿真结果和板端输出逐级核对。由此，模型训练、CPU 端量化和 PL 定点部署保持相同的输入预处理、类别顺序和判定含义，同时分别适配软件运行库和硬件加速电路。

4.2 CNN 加速电路迭代优化

CNN 加速电路共经历 Round00 至 Round42 的多轮迭代。优化过程中始终保持网络结构、训练权重、输入预处理和二分类输出顺序不变，主要调整卷积计算、特征缓存、数据传输和通道并行方式，使完整网络能够在 XC7Z020 上完成部署。

Round00 首先通过自动生成的 HLS 工程验证网络计算流程，但完整 CNN 的初始估算达到 977,180 个 LUT、722,487 个触发器和 1,256 个 BRAM18K，远超目标器件容量。分析生成电路后发现，资源消耗主要来自通用全局平均池化结构、全通道并行展开、宽浅 FIFO、卷积窗口缓存以及大量中间累加状态。该结果主要用于定位资源热点，正式的前后对比采用后续已经形成完整 CNN 电路的版本。

Round01 至 Round20 分别对高资源模块进行拆分和替换。全局平均池化改为按通道分组累加，卷积输入和输出由全通道同时传输改为分组传输；中间数据采用显式打包，FIFO 和行缓存根据实际容量绑定到寄存器或 BRAM；最大池化由通道完全展开改为分组处理；不同卷积层分别建立与其输入尺寸匹配的滑动窗口。上述调整逐步消除了自动生成结构中的冗余并行逻辑。

Round21 至 Round35 将已验证的局部模块重新接入完整网络，并通过软件定点参考、C 仿真和 RTL 仿真检查各层输出。Round35 已经能够完成整网计算，80 MHz 下单帧 RTL 耗时约为 36.353 ms，但占用 12,246 个 Slice，达到器件 Slice 资源的 92.08%，难以继续接入视频通路、质量门控和 DMA 等系统模块。因此，后续优化重点由单纯缩短计算时间转向降低完整 CNN 的物理资源占用。

Round36 至 Round38 重新组织卷积数据通路。电路使用按地址访问的循环行 RAM 保存相邻像素，只保留当前通道组的计算和累加状态；内部采用 64 位数据单元，每个数据单元传输 8 个 8 位通道，避免在模块间传递全通道宽向量。卷积乘加由大量 LUT 逻辑改为 DSP 实现，四个卷积层统一采用 8 路输出通道并行。Round38 完整分组核的 Slice 占用降低至 1,577 个，但单帧耗时增加到 64.517 ms，说明资源已经明显收敛，但计算并行度仍需进一步调整。

分析各层计算量后发现，首层 7×7 卷积约占四个卷积层总乘加次数的 57.65%，是整网主要耗时来源。Round39 将首层并行度由 8 路提高至 16 路，其余三层保持 8 路并行，并将首层输出拆分为两个 8 通道数据单元向后传输。该调整仅增加 46 个 Slice 和 5 个 DSP，BRAM 占用保持不变，使 RTL 单帧耗时由 64.517 ms 降低至 48.795 ms，下降 24.37%。主要版本的资源和时延变化见表 14。

完整 CNN 版本	**Slice**	**LUT**	**触发器**	**BRAM Tile**	**DSP**	**80 MHz 单帧 RTL 耗时**
Round35 完整核	12,246	30,459	47,925	68	0	36.353 ms
Round38 分组核	1,577	3,798	3,420	65	35	64.517 ms
Round39 首层 16 路核	**1,623**	**4,002**	**3,808**	**65**	**40**	**48.795 ms**

表 14 CNN 加速电路主要优化版本的资源与时延对比

与 Round35 相比，Round39 完整 CNN 核的 Slice、LUT 和触发器占用分别降低 86.75%、86.86%和 92.05%。虽然单帧计算时间由 36.353 ms 增加至 48.795 ms，但为视频通路、质量门控、DMA 和控制接口保留了足够资源，使 CNN 能够接入完整系统。该过程体现了加速电路在计算并行度、片上存储和系统资源之间的实际取舍。

Round40 进一步加入 AXI4-Lite 控制接口、CNN 专用 DMA、HP1 高性能端口和 80 MHz 时钟域，完成加速核与 PS 端的连接。首次上板时，CNN 任务未能正常启动。逐级检查控制寄存器、DMA 状态和复位网络后，发现新增复位模块的低有效辅助复位端被错误连接至常量 0，导致相关模块持续处于复位状态。Round41 修正复位连接后，控制寄存器访问、DMA 传输和连续四帧推理均恢复正常。

Round42 在 Round41 已经完成上板验证的基础上，进一步优化 Conv3 大容量权重 ROM 的组织方式。首种共享输出的 ROM 写法虽然通过 49152 次逐项对照，并将 BRAM 映射结果降为 0，但同时消耗 7730 个 LUT，实质上是将存储资源转移至组合逻辑，因此未被采用。最终方案将 Conv3 权重拆分为两个标准同步 ROM，通过寄存器完成数据选择，在不改变模型权重、定点格式、输出并行度和计算周期的条件下，将 CNN 计算链的 BRAM 占用由 65 个降至 54.5 个。对应 LUT 由 4177 个增加至 4206 个，触发器由 4029 个增加至 4030 个，DSP 保持 40 个，实现了以少量逻辑资源换取片上存储资源下降。

最终板端 CNN 硬件事务平均耗时为 48.864 ms。49152 次 ROM 逐项对照、固定输入测试及 343 张测试图像验证表明，优化前后的权重数据、计算结果和风险判定保持一致。Round42 完成整机集成和上板验证，并作为最终版本用于系统功能测试与实物演示。

4.3 图像质量门控优化

质量门控优化主要围绕三类问题展开：正常画面被错误拒绝、PL 侧时序不收敛，以及实际保存图像与硬件质量结果难以直接对应。项目根据真实画面和板端运行结果逐项定位原因，在不改变亮度和 Sobel 基本计算方法的前提下，调整判定参数、硬件流水线和 PS 侧复核程序。

早期测试中，部分肉眼清晰的皮肤画面仍被质量门拒绝。团队没有直接降低全部门限，而是分别检查平均亮度、暗像素比例、亮像素比例和 Sobel 清晰度。统计结果表明，这些画面的 Sobel 均值约为 95.6～101.7，已经明显高于清晰度下限 20，实际失败原因是暗像素比例为 2.42%～4.01%，超过原先 2%的限

制。因此，仅将暗像素比例上限由 2%调整为 5%，平均亮度范围 40～210、亮像素比例上限 2%和 Sobel 均值下限 20 保持不变。调整后，真实皮肤场景获得 137 份连续稳定通过的状态记录，避免了因局部阴影造成的大量误拒绝。

质量门最初采用较长的组合逻辑完成 RGB 灰度计算，首次布局布线的建立时间裕量为−2.430 ns。优化时将灰度计算拆分为乘积寄存和求和两个阶段，并同步延迟像素有效信号、帧标记和配置编号，使统计结果仍与对应像素保持一致。加入动态检测框后，边界比较和控制信号又形成新的关键路径，建立时间裕量一度为−1.171 ns。随后将检测区域边界提前计算，在帧开始时统一锁存，并在视频背压期间同时冻结像素与控制状态。最终视频与质量门工程的建立时间裕量达到+0.147 ns，保持时间裕量为+0.009 ns。

自动抓拍联调时还发现，PL 侧产生抓拍请求后，PS 实际取得的 VDMA 缓冲图像未必能够直接认定为产生该请求的同一帧。为保证 CNN 使用的确实是合格图像，程序在叠加提示信息和释放缓冲区前复制原始 640×360 图像。之后 PS 按照与 PL 一致的整数规则重新计算亮度、暗亮像素比例和 Sobel 清晰度。只有实际送达图像连续 3 次复核合格后，系统才保存最后一张图像并启动后续处理。保存时同步记录质量指标和图像哈希，最终抓拍测试中的 16 项图像、统计值、标志位和文件检查均通过。

PS 侧复核程序最初使用多个完整尺寸的 int32 中间数组，重复生成灰度图、梯度图和布尔掩码，单张图像平均耗时为 330.534 ms。第一次优化将中间数据改为更窄的数据类型，并减少重复数组构造，平均耗时降低至 199.088 ms。随后进一步采用分行中间量、原位统计和经过数值范围验证的 int32 累加，减少大数组分配与内存访问，最终平均耗时降低至 153.969 ms。两轮优化均保持原有整数计算规则和质量判定结果不变，累计减少 53.42%的复核时间。

优化项目	优化前	优化方法	优化后
暗像素比例上限	2%，正常皮肤局部阴影容易触发拒绝	分解各项失败原因，只调整暗像素条件	5%，其余曝光和清晰度门限保持不变

灰度计算关键路径	WNS 为−2.430 ns	乘积寄存、分级求和，同步延迟帧级控制信号	原灰度计算关键路径消除；加入动态检测框后，新的关键路径 WNS 为−1.171 ns
动态检测框关键路径	WNS 为−1.171 ns	边界预计算、帧开始统一锁存、背压时冻结控制状态	完整工程 WNS 为+0.147 ns，WHS 为+0.009 ns
抓拍图像确认	PL 请求与 PS 缓冲图像不能直接对应	对实际取得的原始图像进行同规则复核并记录哈希	图像及记录 16 项检查全部通过
PS 单张质量复核	330.534 ms	窄中间量、原位统计和减少大数组构造	153.969 ms，减少 53.42%

表 15 图像质量门控主要优化内容及结果

优化后的 PL 质量统计结果以约 60.005 帧/s 的速率持续发布，与 720p60 视频输入保持一致。PS 侧复核仅在候选抓拍图像上执行，不参与每个视频帧的实时处理，因此不会阻塞主视频通路。最终系统在保持实时预览的同时，完成质量检测、连续合格判断、实际图像复核和自动抓拍，为 CNN 推理提供质量相对稳定的输入图像。

4.4 系统优化与 PS/PL 联合调试

各模块独立运行后，系统已经能够完成视频预览、质量检测、CNN 推理和结果显示，但 PS 端仍存在重复的数据转换、页面绘制和文件编码操作。这些操作不会改变模型精度，却会延长抓拍后的等待时间。系统优化因此重点调整图像传输、输入预处理、结果页生成和文件保存，并在保持各模块输入输出不

变的条件下完成 PS/PL 联合验证。

系统数据通路按照任务特点分别组织。720p60 视频流通过 VDMA 和 HP0 端口完成帧缓存读写，质量门在 PL 侧视频支路中连续统计，不占用 PS 逐帧计算时间；CNN 只在图像连续合格并完成抓拍复核后启动，输入输出通过独立 DMA 和 HP1 端口传输。PS 端负责模式选择、质量状态读取、图像预处理、推理启动、风险概率计算、页面显示和文件保存。该结构避免对实时视频逐帧执行 CNN，使视频预览、质量判断和推理任务能够在同一系统中分别运行。

首次系统整合时，正常模式只需要完成一次推理，三帧融合模式则需要依次处理三张图像。早期程序在每张图像上重复执行浮点归一化、定点转换、数据打包和统计检查。由于输入图像为 8 位 RGB 数据，每个通道只有 256 种可能取值，后续版本预先生成 3×256 的归一化与定点转换表，通过像素值直接查询对应结果。该方法保持 RGB 顺序、均值、标准差、取偶方式和饱和规则不变。单张图像的预处理、打包和记录生成时间由 92.663 ms 降低至 63.464 ms，减少 31.51%。

结果页面原先每次都重新创建 1280×720 背景，重复绘制固定标题、按键提示和文字内容，保存状态变化后还需要再次生成页面。优化后，程序在启动阶段预先生成正常模式和三帧融合模式的静态页面模板，只更新风险结果、概率、耗时、图片和保存状态等动态内容；常用文字渲染结果采用有限容量缓存，减少重复字体绘制。结果页单次生成时间由 193.640 ms 降低至 70.117 ms，减少 63.79%，页面布局、颜色和显示字段保持不变。

文件保存环节最初使用 PNG 默认压缩参数，ARM 端需要较长时间完成无损编码。项目将 PNG 调整为较低压缩级别，仍保持无损保存和像素回读校验。固定图像对照中，单张 PNG 编码及写入平均耗时由 1286.077 ms 降低至 222.812 ms，减少 82.68%。对应文件体积由 241,600 字节增加至 281,694 字节，增加 16.60%。考虑到板端存储空间能够满足当前采集规模，采用适度增加文件体积换取更快保存的方案。普通模式完整归档中位数由 1564.192 ms 降低至 529.814 ms，三帧融合模式由 5133.031 ms 降低至 1458.033 ms。

优化项目	优化前	优化后	降幅
单张图像预处理、打包及记录生成	92.663 ms	**63.464 ms**	**31.51%**
单次结果页生成	193.640 ms	**70.117 ms**	**63.79%**
单张 PNG 编码及写入	1286.077 ms	**222.812 ms**	**82.68%**
正常模式相关组件合计	496.759 ms	**298.868 ms**	**39.84%**
三帧融合模式相关组件合计	1066.306 ms	**737.789 ms**	**30.81%**
正常模式完整归档中位数	1564.192 ms	**529.814 ms**	**66.13%**
三帧融合完整归档中位数	5133.031 ms	**1458.033 ms**	**71.60%**

表 16 PS 端关键软件环节优化前后对比

表中的组件合计仅包括质量复核、模型输入生成和结果页生成，不包括等待图像质量合格、CNN 计算、视频传输和文件归档。因此，表中数据只用于评价本次 PS 端软件优化，不表示整机总响应时间按相同比例下降。

PS/PL 联合调试过程中，CPU 模型和 PL 加速器统一使用相同的 128×128 RGB 输入、归一化参数、类别顺序和输出含义。以标准化 FP32 输入到两个原始得分输出为统一计时范围，ARM 端 FP32、KL INT8 和 EQ INT8 的平均耗时分别为 92.900 ms、72.859 ms 和 72.885 ms，PL 端完整调用平均耗时为 69.498 ms。PL 端完整调用平均耗时较 ARM KL INT8 降低约 4.61%。卷积、池化和全连接等重复计算转移至硬件电路后，PS 能够继续处理视频控制、图像复核、结果融合、页面交互和文件保存。

联调时按照硬件加载、控制寄存器访问、DMA 输入、CNN 启动、结果读取和阈值判定的顺序逐级检查，并对 CPU 端、软件定点参考和 PL 端输出进行统一比较。三帧融合模式确认每张图像分别启动一次 CNN，PS 对三组原始得分求平均后再计算融合概率，避免将“连续三帧质量合格”误写成只对最后一帧推理。

最终工作版本采用 Round42 硬件和优化后的 PS 程序。真实界面测试中，正常模式从质量复核完成到结果页首次显示的平均时间为 220.064 ms，三帧融合模式为 463.814 ms。系统完成 6 组正常模式和 2 组三帧融合模式测试，共处

理 12 张图像并执行 12 次 CNN 推理，8 组结果均完成保存和导出，视频 DMA、CNN 复位、缓冲区及界面资源均能在任务结束后正常释放。该测试用于确认 PS 端优化没有改变推理次数、页面字段和结果存档逻辑，5.3 节另对 Round42 最终整机进行连续运行验证。

5. 整机实现与综合验证

5.1 整机实物与硬件连接

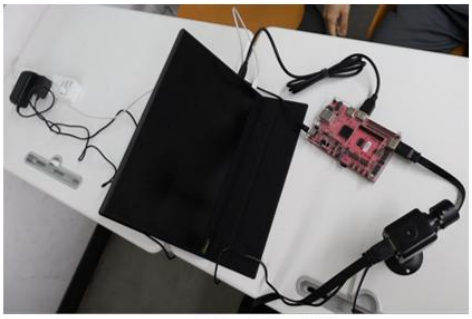
系统以 PYNQ-Z2 开发板为核心搭建，板载器件为 AMD Zynq-7000 XC7Z020，外接 HDMI 摄像头、HDMI 显示屏和存储系统，构成图像采集、实时处理、风险预筛与结果保存一体化的板端终端。开发板由 microSD 卡启动 PYNQ 3.1.1 系统，PL 侧加载包含视频通路、质量门控、CNN 加速核心和 DMA 接口的整机位流，PS 侧运行控制与交互程序。

硬件连接中，摄像头接入开发板 HDMI 输入接口，采集的 1280×720、60 帧/s 视频经 PL 侧视频通路处理后，由 HDMI 输出接口送至显示屏。板载 DDR 作为视频帧缓存及 PS/PL 之间的数据交换空间，用于实时预览、原始图像抓拍和 CNN 输入准备。开发板通过网络接口接入本地计算机，用于程序部署、运行记录查看及结果文件取回；供电接口为开发板、视频输入和输出通路提供稳定运行条件。

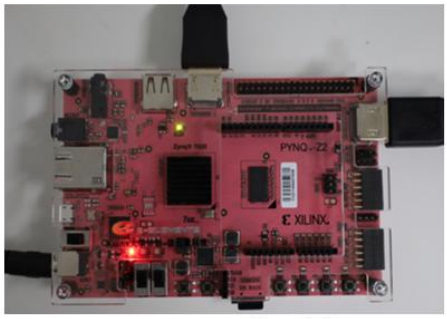
系统启动后，显示屏首先呈现工作模式选择界面。操作者可直接使用板载按键完成模式切换、功能确认、再次采集和返回菜单，无需外接键盘或鼠标。进入采集页面后，摄像头画面、质量检测状态和取景框均实时显示；质量条件满足后，系统自动完成抓拍、CNN 推理、结果显示和本地保存。整机连接关系及开发板主要接口如图 11 所示。



（a）系统连接关系示意



（b）整机实物连接



（c）PYNQ-Z2接口连接

图 11 整机实物与硬件连接

5.2 完整操作流程与交互界面

系统启动后自动进入主菜单，提供正常模式、三帧融合推理和结果导出三项功能。操作者通过板载按键切换选项并确认，无需连接键盘或鼠标。正常模式在获得一张质量合格图像后进行单帧风险预筛；帧融合模式依次获取三张质量合格图像，分别完成 CNN 推理并对三组原始得分求平均后完成融合判定；结果导出功能用于统一整理已经保存的图像和结果记录。系统主菜单及实时质量检测界面如图 9 所示。

进入采集页面后，被拍摄者将待拍部位置于摄像头取景范围内，显示屏同步呈现实时画面、亮度、清晰度、连续合格计数及质量提示。操作者可根据取景框颜色和提示文字调整拍摄位置、距离与光照。图像质量满足要求后，系统自动完成抓拍、复核和风险预筛，不需要操作者手动选择拍摄时刻。图 12 展示了摄像头、开发板、显示屏和被拍摄者共同参与的实际采集过程，验证了视频输入、质量检测、自动抓拍和板端交互能够在整机状态下协同运行。

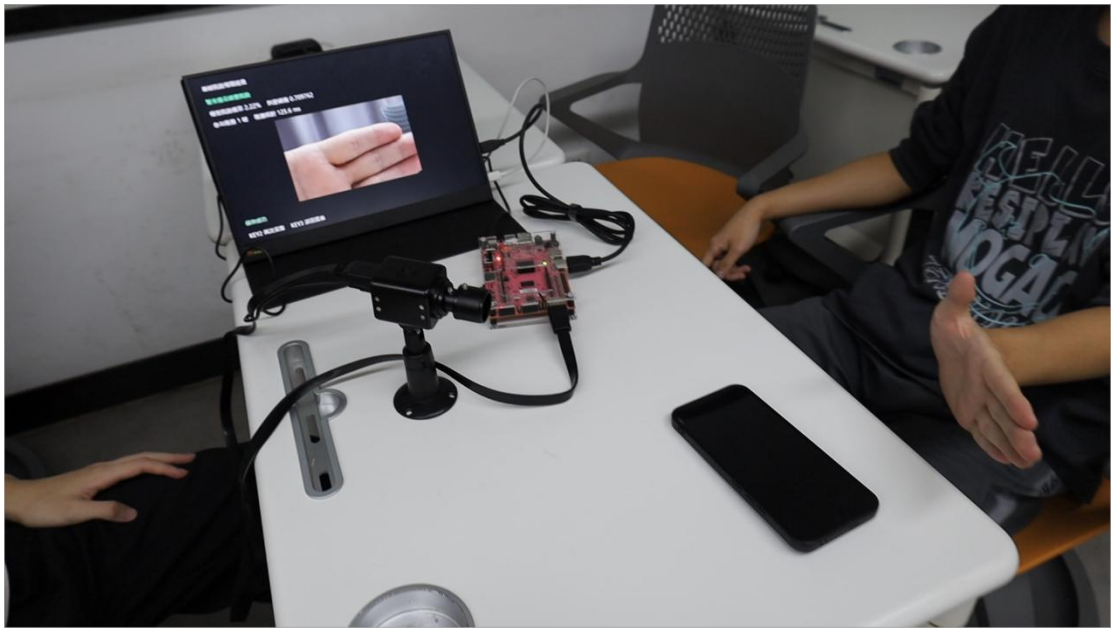


图 12 整机实际采集过程图

完成推理后，系统进入结果页面，显示抓拍图像、风险提示、风险概率、判定阈值、参与推理帧数和推理耗时。三帧融合模式还会列出三次推理结果，使最终风险提示的形成过程可以核对。单帧与三帧融合结果界面如图 10 所示。

为覆盖“建议就医”输出分支，验证过程中将项目所用公开数据集中的皮肤病变样例显示于移动终端，再由摄像头进行实际采集，检查质量门控、自动抓拍、CNN 推理、阈值判定、三帧融合和结果保存等环节。该测试用于验证系统正向提示路径和整机功能，模型分类性能仍以固定测试集的批量评估结果为准。

每次风险预筛完成后，系统自动保存抓拍图像及对应结果。操作者在主菜单中选择“导出结果”后，程序对已保存内容进行核对和整理，生成包含有效图像及结果信息的压缩文件，并显示文件名称、有效结果数量、跳过数量和保存位置。归档文件可通过网页或 SSH 从板端取回，从而完成从实际采集到结果保存和导出的完整操作流程。



（a）结果导出完成界面



（b）推理快照与日志记录存档

图 13 结果存档与导出验证

每次任务完成后，系统按照独立编号建立存档目录，保存参与推理的原始图像及对应的`result.json`文件。日志中记录工作模式、风险概率、判定阈值、参与推理帧数、推理耗时和质量复核信息，便于后续核对与导出。图 13（a）展示的是测试目录中此前多轮功能验证结果的累计导出，共包含 44 条有效记录；表 17 中的 7 组结果仅统计 Round42 最终版本 240.004 s 连续运行测试期间完成的任务，二者统计范围不同。

5.3 系统级性能、资源占用与稳定性

整机验证采用 PYNQ-Z2 开发板、HDMI 摄像头和 HDMI 显示屏，硬件加载 Round42 完整系统位流，PS 端运行最终版本控制与交互程序。测试覆盖实时取景、图像质量检测、正常模式推理、三帧融合推理、结果显示、本地保存和

批量导出等功能。

视频输入保持在 1280×720、60 帧/s。PL 侧质量门控统计速率约为 60.005 帧/s，与视频输入帧率基本一致，能够在不中断实时预览的情况下持续完成亮度、暗亮像素比例和 Sobel 清晰度计算。CNN 硬件事务平均耗时为 48.864 ms；计入输入定点转换、DMA 传输和输出检查后，完整 PL 调用平均耗时为 69.498 ms。上述计时针对单张模型输入，不包含等待图像质量合格、结果页面生成和文件保存时间。

为验证最终版本的完整运行过程，系统进行了 240.004 s 的 UI 主循环测试，共完成 4 次正常模式任务和 3 次三帧融合任务。7 次任务实际处理 13 张业务输入图像，并完成 13 次业务 CNN 推理。系统启动阶段另执行 4 次固定输入自检，因此本次测试共调用 CNN 17 次。测试期间生成 7 组结构化结果记录和 13 张对应图像，并成功完成 1 次批量导出，未记录程序运行异常。

验证项目	测试结果
视频输入规格	1280×720，60 帧/s
PL 质量门控统计速率	约 60.005 帧/s
UI 主循环运行时间	240.004 s
正常模式完成次数	4 次
三帧融合模式完成次数	3 次
业务输入图像数量	13 张
业务 CNN 推理次数	13 次
固定输入自检次数	4 次
CNN 调用总次数	17 次
结果记录数量	7 组
保存图像数量	13 张
批量导出	成功 1 次
记录异常	0 次

表 17 最终版本整机运行验证结果

表中的 CNN 调用总次数包括 13 次业务推理和 4 次系统启动自检，业务输入图像数量不包含实时视频预览帧。该项测试主要验证系统功能衔接、任务计数、结果保存和连续运行情况；模型分类性能仍采用第三章中 343 张测试图像的统一测试结果，不使用本次实物演示图像重新计算准确率。

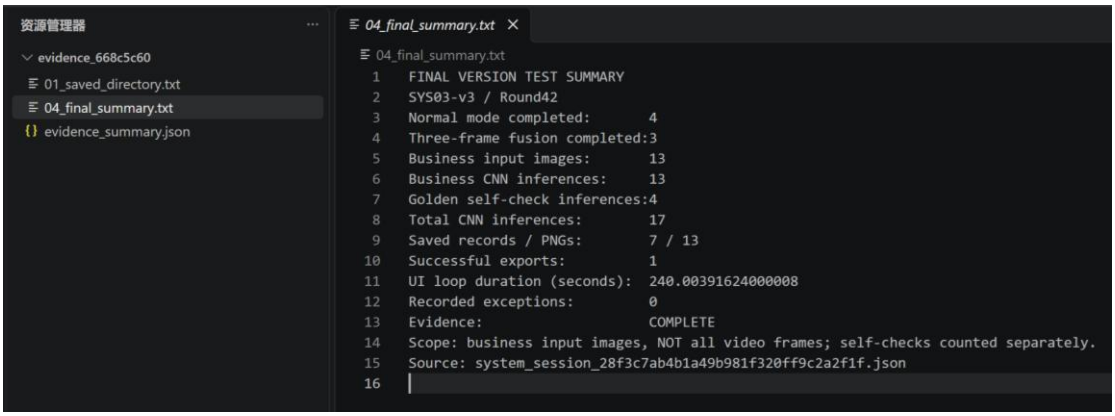


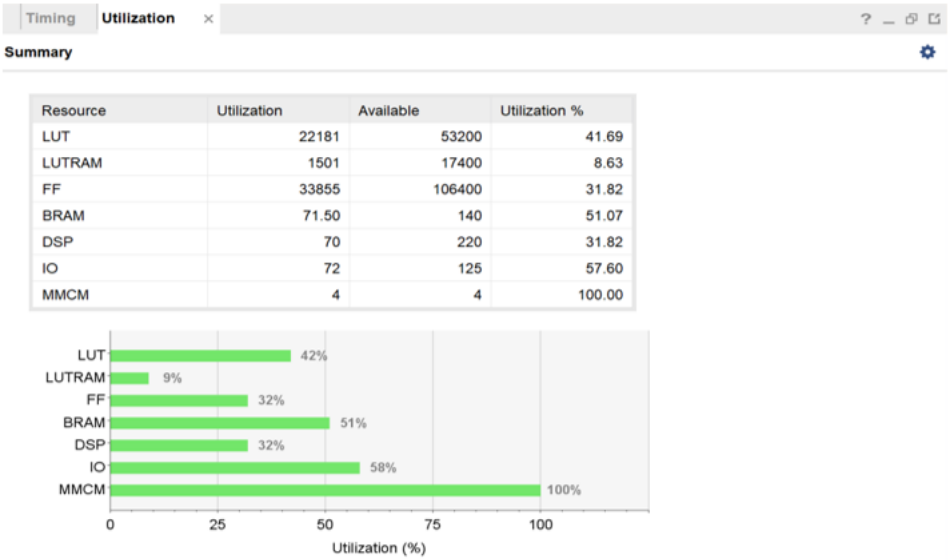
图 14 最终版本整机连续运行测试汇总

Round42 完成布局布线后，完整系统占用 22181 个 LUT、33855 个触发器、71.5 个 BRAM Tile 和 70 个 DSP，分别占器件可用资源的 41.69%、31.82%、51.07%和 31.82%。BRAM 占用最高，但仍保留接近一半的片上存储资源，可满足当前视频通路、质量门控和 CNN 推理电路的共同部署需求。

完整系统的建立时间裕量为+0.099 ns，保持时间裕量为+0.014 ns，建立时间和保持时间的总负裕量均为 0，相关检查均无失败端点，说明 Round42 完整系统满足既定时序约束。资源占用和时序结果见图 15。



（a）时序结果



（b）资源占用

图 15 Round42 完整系统布局布线结果

综合测试结果表明，最终系统能够在同一 Zynq 器件上同时完成 720p60 视频预览、实时图像质量检测、轻量 CNN 推理和 PS 端界面交互。正常模式和三帧融合模式均能按照设定流程完成图像采集、风险预筛、结果保存和批量导出，验证了 PL 视频处理与推理电路、PS 端控制程序以及外部摄像与显示设备的整机协同运行能力

6. 大模型协作记录

项目开发过程中，大模型与代码智能体主要用于工程资料检索、问题定位、候选方案审查、测试脚本辅助和报告数据核对。系统需求、软硬件接口、模型与阈值、优化取舍以及最终验收仍由团队成员确定，Vivado 报告、仿真结果、板端日志和实物测试作为工程结论的直接依据。

6.1 协作定位与任务组织

项目采用“人工确定任务—智能体分析与执行—工具产生证据—人工审查验收”的协作方式。团队成员首先明确需要解决的问题、允许修改的范围和验收标准，再向智能体提供必要的接口说明、工程文件、错误日志和测试结果。智能体在限定范围内完成资料检索、影响分析、候选方案比较和代码或文档修改，最后由确定性工具验证修改效果。

为减少任务范围在协作过程中不断扩大，每项工程任务均尽量明确以下内容：可观察目标、不需要改变的部分、当前代码和硬件基线、允许修改的文件、接口约定、验收方法、最大重试次数以及需要保存的结果。例如，在 Conv3 权重存储优化中，任务目标是降低 BRAM 占用，同时明确不得改变模型权重、定点格式、输出并行度和计算周期。验收不仅检查数值是否一致，还需要检查综合后的真实资源映射、完整 CNN 计算链、时序结果以及整机集成状态。

大模型在这一过程中承担辅助分析和方案整理作用，不直接决定模型类别、质量门控阈值、PS/PL 接口和最终发布版本。当修改可能影响系统架构、数据含义、硬件接口或板端运行安全时，由团队成员重新确认后再继续执行。

6.2 工具反馈与分层验证

大模型给出的代码或判断不能直接作为工程结论。项目将协作过程划分为分析、修改、验证和验收四个阶段。分析阶段只读取当前工程、接口约定和历史错误，确定可能受影响的模块；修改阶段仅在授权范围内形成可回退的差异；验证阶段调用仿真、综合、实现和板端程序产生结果；验收阶段由团队成员结合原始任务和测试证据决定是否保留修改。

不同工具能够证明的范围并不相同。静态检查用于发现语法、文件引用和修改范围问题；固定输入和软件参考用于检查数据布局、定点格式及数值误差；RTL 仿真用于检查复位、握手、背压和多帧行为；Vivado 综合与实现报告用于检查资源映射和时序；板端固定输入测试用于验证位流、寄存器、DMA 和

CNN 输出；整机测试进一步覆盖视频输入、质量检测、自动抓拍、推理、显示和结果保存。较低层验证通过不能直接替代较高层验证，例如，RTL 仿真正确不能说明整机已经上板运行，时序约束满足也不能说明视频与 CNN 功能一定正确。

当验证失败时，协作过程优先保留首个关键错误、当前修改内容和失败输入，再根据新的工具反馈修改一个主要假设。若相同错误重复出现、缺少必要文件、问题超出原接口约定，或者需要放宽精度与时序要求才能通过，则停止自动修改并交回团队成员判断。大模型协作流程如图 16 所示。

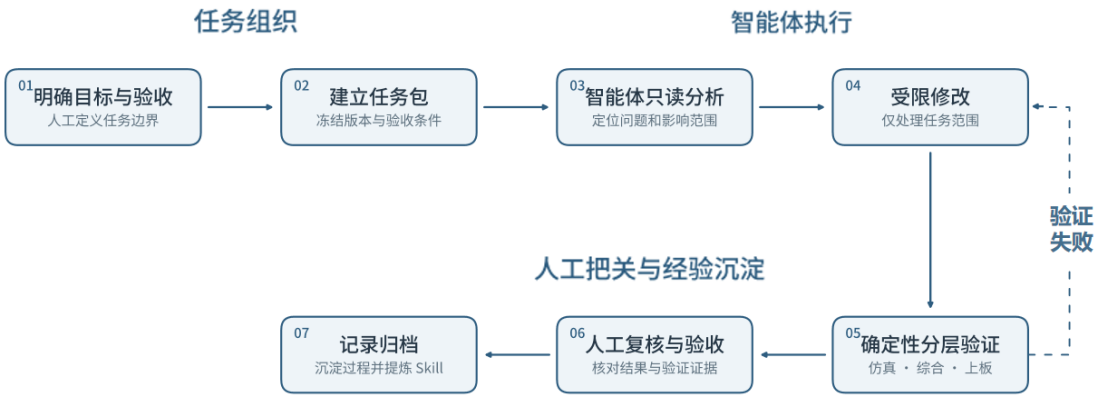


图 16 大模型辅助的工程任务执行与验证流程

6.3 典型协作与纠错过程

项目选择资源优化、首次上板排障和性能结果审查三个案例，说明模型建议如何在工具反馈和人工判断下得到修正。这里所说的纠错是能够从外部观察到的“初始判断—工具反馈或人工纠正—方案修订—再次验证”过程，不涉及对模型内部推理过程的推测。

（1）Conv3 权重存储资源优化

Conv3 权重存储优化过程中，第一种候选方案采用共享输出的 ROM 写法。该方案通过 49152 次逐项数值对照，但综合后 BRAM 映射数量降为 0，同时消耗 7730 个 LUT。工具结果表明，该方案只是将存储资源转移到组合逻辑中，因此即使数值结果正确，也不能认为资源优化成功。团队据此否决该方

案，并将“检查综合后的真实存储原语和完整资源变化”加入后续审查条件。

第二种方案将 Conv3 权重拆分为两个标准同步 ROM，并通过寄存器选择输出。在不改变模型权重、定点格式、输出并行度和 RTL 计算周期的条件下，CNN 计算链的 BRAM 占用由 65 个降至 54.5 个，LUT 由 4177 个增加至 4206 个，DSP 保持 40 个；建立时间和保持时间裕量仍为正。该方案进一步完成完整计算链回归和整机实现，最终集成到 Round42 系统中。该案例说明，大模型可以辅助比较候选结构，但是否保留方案需要同时依据数值、资源、时序和系统集成结果。

（2）PYNQ 首次上板排障

首次整机上板时，独立 CNN 测试已经得到正确输出，完整系统建立时间裕量也满足要求，但板端控制任务仍无法正常启动。协作审查没有直接将问题归因于 DMA 或重复下载位流，而是依次检查硬件描述文件、实际生成的顶层文件、控制寄存器和复位连接。

对 HWH、Block Design 和生成代码进行核对后发现，新增复位模块的低有效辅助复位端被错误连接到常量 0，使相关模块持续处于复位状态。修正复位连接后，系统按照硬件信息读取、位流加载、控制寄存器访问和 DMA 传输的顺序逐级验证，控制访问和连续推理恢复正常。该过程表明，独立模块测试与整机时序通过仍未覆盖真实系统中的复位连接，板端故障必须结合实际硬件结构逐层定位。

（3）性能测试口径审查

系统早期性能测试采用的实拍输入、测试组数和文件写入状态并不完全一致，部分结果还受到 I/O 尖峰影响。大模型与团队成员共同复核测试记录后，将初测结果限定为优化趋势，不直接用于正式性能对比。后续测试固定输入图像，统一预热次数和执行顺序，并分别记录均值、中位数、P95 耗时及原始测试行。

受控复测表明，正常模式完整归档中位数由 1564.192 ms 降低至 529.814

ms，三帧融合模式由 5133.031 ms 降低至 1458.033 ms，但普通模式 P95 耗时没有同步改善。因此，报告将典型耗时改善与尾部波动分开说明，没有将局部优化直接表述为所有响应时间均下降。同时，CNN 硬件事务平均耗时 48.864 ms 与完整 PL 调用平均耗时 69.498 ms 采用不同计时边界，最终报告分别列出，不将二者与其他范围的 CPU 耗时混合计算加速比。

6.4 记录归档与责任边界

协作过程中的有效结果按照任务、工程基线和验证层级进行归档。记录内容包括任务目标、允许修改范围、代码或文档差异、工具版本、测试命令、关键日志、资源与时序报告、板端结果以及人工验收决定。模型、数据、BIT/HWH 和测试结果通过文件版本或哈希进行关联，避免报告数字与实际部署文件来自不同版本。

协作材料按来源分为三类：项目开发期间形成的源码、报告和日志属于历史工程材料；项目完成后根据历史材料整理的流程属于复盘总结；最终整理阶段真实发生的提问、模型输出、人工纠正和案例回放属于新增协作记录。三类材料分别说明其能够支持的结论，不将事后整理内容写成开发阶段的原始记录，也不将同一智能体完成的桌面回放表述为独立复验。

项目中的资源、时序、精度和耗时结论均以确定性工具和实物测试结果为准。大模型提出的候选方案只有在完成对应层级验证并经团队成员确认后，才能进入主线工程。皮肤图像和其他可能包含个人信息的材料保留在本地测试环境，不作为外部提示内容。通过上述方式，大模型协作被限制在可检查、可回退和可追溯的工程范围内，其形成的通用方法进一步整理为第 7 章所述技能包。

7. 技能包提炼与复用

第六章记录了大模型参与工程分析、修改、验证和材料整理的协作过程。本章进一步将项目中反复出现、具有通用处理规律的问题整理为可复用技能包。技能包不保存某一次对话的完整内容，而是记录问题触发条件、所需输

入、处理步骤、验证方法和停止条件。这些内容被整理为可执行流程，使智能体在后续相似任务中按照统一规则开展分析，减少已发现工程错误的重复发生。

7.1 技能包提炼目标与问题来源

本项目同时涉及模型量化、定点运算、RTL 实现、Vivado 布局布线、PYNQ 板端部署、PS/PL 联合调试和性能测试。不同阶段使用的工具、输入和验证范围存在明显差异。例如，软件定点结果正确不能直接证明 RTL 实现正确，独立 CNN 核测试通过也不能证明其接入完整系统后能够正常启动，单项 BRAM 占用下降也可能伴随大量 LUT 增加。若仅保存最终结果，后续面对类似问题时仍需重新判断验证顺序和证据范围。

因此，技能包的提炼重点不是记录具体参数，而是保存具有复用价值的工程判断方法。提炼过程首先从源码、实验记录、Vivado 报告、板端日志和版本迭代材料中筛选重复出现的问题，再区分直接测试结果、工程观察、原因推断和后续计划。与本作品相关的器件型号、寄存器地址、模型阈值和文件路径保留在项目材料中；能够迁移到其他任务的检查顺序、判定规则、验证层级和停止条件写入技能包。

本项目开发阶段没有完整保存全部提示词和模型原始回答，因此技能包主要依据已经形成的工程文件和实验结果，在最终材料整理阶段完成归纳，并通过冻结材料回放检查其适用性。报告只将历史文件能够直接支持的内容写为工程事实，不将后期整理的流程描述为开发初期已经完整实施的工作流。

每个技能包均由三部分组成：`SKILL.md`说明触发条件、输入要求、执行步骤和停止条件；`references.md`记录其来源问题及对应工程材料；`validation.md`记录应用结果、人工修订和当前尚未覆盖的范围。由此将具体工程事实与可复用方法分开保存，同时建立技能规则与原始证据之间的对应关系。

7.2 技能包内容与适用边界

结合项目实际问题，共提炼七个技能包，覆盖模型评估、数值验证、资源优化、性能测试、板端排障、经验整理和智能体协作。

技能包	主要内容	适用任务	当前适用边界
PYNQ Overlay 启动与板端排障	按运行环境、产物身份、复位、控制接口和 DMA 逐层检查	位流加载失败、寄存器无响应、DMA 异常和板端资源不足	短时测试不能证明长期无资源泄漏，不能替代 AXI4-Stream 波形级检查
HLS 数值等价与分层验证	依次核对模型图、数据布局、定点规则、仿真、RTL、实现和板端输出	CNN 定点化、算术位宽修改和软硬件数值对照	少量样本只能用于运行检查，软件仿真通过不能代替 RTL 和板端验证
FPGA 资源—时序—延迟协同优化	联合检查数值正确性、真实物理资源、计算周期、时序和完整链回归	ROM 组织、并行度、位宽和片上存储优化	单项资源下降不能作为保留候选的充分条件，不同工程版本需重新实现验证
异构系统性能测量与受控对照	冻结输入和实现版本，统一计时边界，并同时检查均值、中位数和 P95	CPU/PL 对照、软件流程优化和完整调用计时	文件归档耗时不能表示视频吞吐率，不同计时范围的数据不能直接计算加速比
量化模型参考锁定与候选评估	锁定模型、预处理、数据划分、参考输出、温度系数、阈值和指	FP32 与 INT8 候选比较、工作点选择和板端一致性检查	测试集不能表述为独立盲测，板端一致性不能代替模型泛化和临

	标定义		床有效性验证
工程经验蒸馏与 Skill 迭代	将项目事实、可复用流程、失败记录和证据边界分别归档	阶段复盘、报告整理和技能包更新	不补造缺失的历史记录，当前证据不足时应降低结论强度
智能体工程协作与交接	用任务包限定目标、权限、接口和验收，组织分析、修改、验证与人工审核	大模型辅助工程修改、材料核对和任务交接	当前主要验证了单智能体受限协作，尚不能证明完整多智能体自动编排已经实现

表 18 技能包内容与适用范围

上述技能包之间并非相互独立。例如，量化候选确定后，需要使用数值验证技能包检查软件定点参考、RTL 和板端输出；硬件结构发生变化后，还需使用资源优化技能包重新核对资源、时序和计算周期；完成上板后，再使用性能测量技能包统一计时范围。智能体工程协作技能包负责限定任务范围和验收方式，工程经验蒸馏技能包则负责将新的失败、修正和验证结果补充到相应技能中。

实际使用时，将对应的`SKILL.md`与当前任务目标、接口文件、输入数据和日志一并提供给智能体。智能体只读取完成当前任务所需的技能包，避免一次性加载无关规则。若任务涉及新的器件、工具版本、数据分布或系统接口，技能包只提供检查顺序和判断方法，具体结论仍需根据当前工程重新验证。

7.3 技能包复用与有效性验证

技能包的有效性检查采用“历史问题回放、规则执行、结果对照和人工修订”的方式。首先向智能体提供冻结的历史材料，由其按照技能包给出的步骤分析问题和判断证据范围；随后将分析结果与项目后续实际修复及测试结果进行对照。该过程用于检查技能包能否帮助定位问题、识别错误结论和保持验证边界，不等同于重新进行一次板端实验。

在资源优化案例中，Conv3 权重 ROM 的第一种候选写法通过了 49152 次逐项数值对照，并将 BRAM 映射数量降为 0，但同时消耗 7730 个 LUT。按照资源—时序—延迟协同优化技能包，BRAM 下降只能说明存储资源发生转移，不能直接认定优化成功，因此该候选被否决。该结果表明，技能包能够阻止仅依据单项资源数据选择硬件方案。

在 PYNQ 首次上板问题中，独立 CNN 测试和完整系统时序均已通过，但板端控制访问仍无法正常启动。按照 Overlay 启动与排障技能包，问题被拆分为运行环境、位流与 HWH 身份、复位状态、控制寄存器和 DMA 五个层级，避免反复下载位流或直接将问题归因于 DMA。历史工程结果最终确认问题来自完整系统中的复位连接，说明分层检查能够缩小故障范围。

在性能结果审查中，固定输入复测显示正常模式完整归档耗时的中位数由 1564 ms 降至 530 ms，但 P95 由 1753 ms 升至 2697 ms。性能测量技能包要求同时检查典型值和尾部数据，因此保留了软件优化降低典型耗时的结论，也指出普通模式仍存在偶发长延迟，避免将局部改善直接写成整体稳定性提升。

在模型与数值验证方面，技能包能够区分少量固定参考样本检查、完整数据集评估、RTL 验证和板端批量推理。最终 343 张图像的板端输出可用于证明当前定点模型与软件参考在冻结输入和工作点下保持一致，但不能据此将测试集表述为独立盲测，也不能替代外部数据上的泛化能力验证。

综合回放结果表明，七个技能包能够覆盖本项目中已经出现的主要工程问题，并帮助智能体保持输入身份、验证层级和结论范围的一致。当前验证结论为通过但保留适用边界：部分技术技能已经由项目实际结果支持，技能整理与任务交接流程也在最终材料收束中得到应用；但尚未完成跨项目、跨工具版本和独立多智能体协作验证。

后续项目使用过程中，可将新的任务结果、失败原因和人工反馈继续写入对应的`validation.md`。当原有流程无法覆盖新的问题时，应先保留失败条件和原始证据，再修改技能步骤，而不是直接扩大原有结论。通过持续应用和修订，技能包可以由本项目的工程经验逐步发展为适用于同类 Zynq 异构系统开

发的辅助方法。

8. 项目复现说明

本项目以公开仓库 DermaFlow（https://github.com/Foracia/DermaFlow-A-Zynq-Based-Skin-Lesion-Risk-Pre-Screening-System）作为复现起点，仓库根目录即工程根目录。复现者不需要重新训练模型、量化参数或生成 FPGA 位流，只需将发布包部署至 PYNQ-Z2，连接摄像头和显示器，即可运行已经完成集成的整机程序，复现实时取景、图像质量检测、自动抓拍、CNN 推理、结果显示与文件保存功能。发布包同时保留源码、仿真材料和实现报告，用于核对系统结构及测试结果。

8.1 复现包组成与文件说明

发布包按照设计源码、板端程序、模型数据、测试结果和报告材料进行分类。复现整机功能时，主要使用`board/`目录中的位流、硬件接口文件和系统程序。各主要文件及用途如表 19 所示。

文件或目录	主要内容与用途
README.md	发布包总体说明，介绍目录结构、运行环境和主要入口
requirements.txt	板端程序使用的 Python 依赖，包括 NumPy、Pillow 和 psutil
board/run_ui.py	完整系统界面入口，用于检查部署文件或启动交互程序
board/hardware/cnn_system.bit	已生成的整机 FPGA 位流，包含视频通路、质量门控、CNN 加速和 DMA
board/hardware/cnn_system.hwh	与位流配套的硬件接口描述，供 PYNQ 解析 IP 地址和接口信息
board/hardware/manifest.json	记录位流、HWH 和配套配置文件的身份信息，用于检查部署文件是否匹配

board/hardware/board_stage_probe.py	开发诊断工具，分阶段检查 HWH 解析、位流加载和控制接口状态
board/system_ui/	板端交互程序，包含菜单、按键、视频采集、质量复核、推理、结果保存和导出功能
data/models/	保存模型接口、预处理方法、数据划分和 PL 定点参数
board/results/	保存已有板端启动、固定输入测试、批量评估和完整系统运行记录
src/、sim/和 build/	保存设计源码、仿真材料和 Vivado 构建文件，主要用于工程检查和后续开发
skill/和 report/	保存技能包、大模型协作材料及报告支撑材料
board/boot/boot.py	统一管理 FPGA 配置加载
board/boot/README.md	首次安装、核对及重启步骤
build/scripts/deploy_build.py	重建位流部署、接口核对及清单刷新

表 19 项目复现包主要文件及用途

复现时应整体复制完整工程，不单独提取`run_ui.py`或位流文件。`cnn_system.bit`和`cnn_system.hwh`必须作为配套文件使用，板端程序、工作点参数及清单文件也应保持发布包中的原有版本，避免不同迭代版本混用。

8.2 板端部署与系统启动

复现平台为 PYNQ-Z2，板端使用 PYNQ 3.1.1 和 Python 3.10.4 环境。外部设备包括 HDMI 摄像头、HDMI 显示器及相应电源。摄像头 HDMI 输出连接开发板 HDMI 输入端口，开发板 HDMI 输出端口连接显示器；上位机可通过网口或 USB 转网口与开发板连接，用于复制发布包和取回运行结果。

将完整发布包复制到板端后，进入工程根目录。首先运行`board/run_ui.py`进行文件检查，程序在不访问硬件的情况下核对系统软件、位流、HWH 及清

单文件。首次安装时按 board/boot/README.md 完成随包 boot.py 安装并重启；随后进入工程根目录，执行 python3 board/run_ui.py --load --run 启动完整系统。程序进入主菜单后，KEY0 和 KEY1 用于切换正常模式、三帧融合模式及结果导出选项，KEY2 用于确认或再次采集，KEY3 用于返回上一级界面。

正常模式在取得一张质量复核合格的图像后完成 CNN 推理；三帧融合模式连续取得三张复核合格图像，分别完成推理并融合三组结果。系统退出时自动释放摄像头、视频通路、DMA 和 CNN 缓冲区。

8.3 功能复现与结果检查

系统启动后，首先检查显示器能否持续输出实时预览画面。摄像头移动或场景变化时，画面应连续更新，不应出现长时间黑屏、冻结或明显颜色异常。

随后分别构造过暗、过亮、模糊和质量合格的画面，检查取景框颜色、亮度、清晰度、连续合格计数和拒绝原因是否随当前画面变化。质量不合格时，系统应继续等待下一帧，不进入 CNN 推理；连续质量合格后，系统完成抓拍和 PS 侧复核。

选择正常模式时，系统应显示单帧风险概率、判定阈值、参与推理帧数和最终提示，并保存一张参与推理的图像。选择三帧融合模式时，系统应显示三张图像各自的推理概率、融合概率和最终提示，参与推理帧数应为 3。

每次完成推理后，系统在`board/system_ui/runs/`下建立本次运行记录。其中，`captures/`保存采集图像和对应的`result.json`，`index.csv`保存各次结果的索引信息。执行主菜单中的导出功能后，系统将完整记录整理为压缩文件，并保存至`captures/exports/`目录。

复现完成后，应确认以下功能均能够正常执行：

1. 主菜单选择和板载按键响应正常；
2. HDMI 摄像头输入和显示器预览正常；
3. 过暗、过亮和模糊画面能够被质量门控拒绝；

4. 正常模式能够完成单帧推理并保存结果；

5. 三帧融合模式能够完成三次推理及结果融合；

6. PNG 图像、JSON 结果和 CSV 索引能够对应保存；

7. 已保存结果能够通过主菜单导出；

8. 程序退出后能够再次启动，不遗留视频或 DMA 占用。

上述检查用于确认发布包能够在 PYNQ-Z2 上复现作品的完整操作流程。模型准确率、CNN 推理耗时以及整机资源和时序采用第三章和第五章中的统一测试结果，不通过少量实物演示图像重新计算。

9. 总结与展望

9.1 工作总结

本项目面向基层医疗、社区健康服务和义诊巡检中的皮肤病变图像采集与风险预筛需求，设计并实现了一套基于 PYNQ-Z2 的异构计算终端。系统将实时取景、图像质量检测、自动抓拍、CNN 推理、结果显示和本地存档连接为连续流程，在板端完成皮肤病变图像的规范化采集与风险预筛，无需依赖云端服务器传输和处理原始图像。

系统根据任务特点完成 PS/PL 软硬件划分。PL 侧负责 720p60 视频处理、曝光与清晰度检测、质量状态叠加和 CNN 定点推理，PS 侧负责抓拍复核、输入预处理、模式控制、三帧融合、界面交互及文件管理。项目完成了轻量 CNN 训练与量化，并对 CNN 加速电路进行了 Round00 至 Round42 的多轮迭代。在此基础上，项目进一步优化质量门控时序、PS 端数据处理和文件保存流程，实现视频通路、质量门控、推理加速与交互程序的板端协同运行。

板级测试表明，质量门控能够以约 60 帧/s 的速率持续处理视频；PL 定点模型在测试集上的总体准确率为 86.88%，AUC 为 92.38%；完整 PL 推理调用平均耗时为 69.498 ms。系统能够稳定完成单帧和三帧融合预筛，并自动保存、

核对和导出图像及结果记录。界面通过质量未通过原因、模型风险概率、判定阈值和多帧融合结果展示采集与判定过程，增强了风险预筛结果的可核对性。上述结果验证了 Zynq 异构架构在低资源条件下同时承担实时视频处理、图像质量控制和神经网络推理的可行性。

9.2 后续展望

面向基层医疗、社区健康服务和义诊巡检中皮肤科专业人员有限、专业设备配置不足的问题，后续将推动系统向便携式应用终端发展。后续可将摄像头、补光装置、显示屏和 Zynq 计算平台集成为便携式终端，进一步缩小设备体积并简化接线。基层工作人员可通过按键完成取景、质量判断、自动抓拍和风险预筛，减少设备使用对专业拍摄经验和外部计算条件的依赖。

针对普通摄像条件下光照、距离、角度和手持稳定性难以统一的问题，可继续落实初始技术路线中的病变区域自动定位与自适应质量检测。系统可根据病变在画面中的位置和大小动态调整检测区域，并增加拍摄距离、病变覆盖程度和颜色偏差检测，根据环境光照自动调整质量阈值。实现这些功能后，设备能够主动提示操作者移动摄像头、调整距离或改善光照，进一步提高不同操作者和不同场景下采集图像的一致性。

在现有二分类风险预筛基础上，后续还可加入初始技术路线中规划的模型拒识机制。当风险概率接近判定阈值、三帧推理结果差异较大或输入图像偏离模型训练数据分布时，系统不强制输出风险结论，而是提示重新采集或转交专业人员复核，减少模型把握不足时产生错误提示的可能。随着数据规模扩大，模型还可由二分类预筛逐步扩展至风险分级和病变类型提示；在现有风险概率、判定阈值和多帧结果展示基础上，进一步增加病变关注区域或特征响应热图，使工作人员能够了解模型主要依据图像中的哪些区域形成判断。

未来可与医疗机构合作，补充不同地区、肤色、设备和拍摄条件下的皮肤病变图像，并重点增加现有数据中数量较少的风险类别，通过外部数据和真实应用场景验证模型的泛化能力。系统仍以本地推理和本地保存为主，在受检者授权后支持规范化图像及结果记录的安全导出。上述功能完善后，系统可以帮

助基层机构获得质量相对一致的皮肤病变图像、识别模型难以判断的情况并确定后续检查优先级，使有限的皮肤科专业资源优先服务于更需要进一步检查的人群。

参考文献

[1] WORLD HEALTH ORGANIZATION. Skin diseases as a global public health priority: EB156(24)[R/OL]. Geneva: World Health Organization, 2025-02-10[2026-10-30].

[2] I J, ZENG J. Burden of dermatology outpatient and inpatient services in China, 2011–2023[J]. Frontiers in Public Health, 2026, 14: 1917511. DOI: 10.3389/fpubh.2026.1917511.

[3] LIU X, WAN P, XU B, et al. Chinese dermatologists' perceptions of clinical practice: a national cross-sectional questionnaire survey[J]. Archives of Dermatological Research, 2026, 318: 367. DOI: 10.1007/s00403-026-04792-4.

[4] AMD. Zynq-7000 SoC Technical Reference Manual: UG585, Version 1.15[EB/OL]. 2026-02-06[2026-10-30].

[5] 中南大学新闻网. 中南大学 AIMADS 团队获 2019 中国高校计算机大赛—人工智能创意赛特等奖[EB/OL]. 2019-11-28[2026-10-30].

[6] 中南大学人工智能与机器人实验室. 基于卷积神经网络的皮肤病诊断系统研究[EB/OL]. [2026-10-30].

[7] 全国人民代表大会常务委员会. 中华人民共和国个人信息保护法[Z/OL]. 2021-08-20[2026-10-30].

[8] 东南大学新闻网. 东大学子在全国大学生嵌入式芯片与系统设计竞赛中获得一等奖[EB/OL]. 2024-12-26[2026-10-30].

[9] FPGA 开发圈. AMD 助力全国大学生 FPGA 创新设计竞赛[EB/OL]. 2025-02-06[2026-10-30].

[10] 武汉工程大学新闻中心. 学校获第八届全国大学生嵌入式芯片与系统设计竞赛全国总决赛一等奖 2 项[EB/OL]. 2025-12-04[2026-10-30].

[11] AMD. AXI4-Stream Video IP and System Design Guide: UG934, Version 1.0[EB/OL]. 2022-11-16[2026-10-31].
[12] AMD. AXI Video Direct Memory Access v6.3 LogiCORE IP Product Guide: PG020[EB/OL]. 2022-06-08[2026-10-31].
[13] ITU-R. Recommendation ITU-R BT.601-7: Studio encoding parameters of digital television for standard 4:3 and wide-screen 16:9 aspect ratios[S/OL]. Geneva: International Telecommunication Union, 2011[2026-10-31].
[14] PACHECO A G C, LIMA G R, SALOMÃO A S, et al. PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones[J]. Data in Brief, 2020, 32: 106221. DOI: 10.1016/j.dib.2020.106221.
[15] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
[16] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for computer vision[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 2818-2826. DOI: 10.1109/CVPR.2016.308.
[17] CUI Y, JIA M, LIN T Y, et al. Class-balanced loss based on effective number of samples[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9268-9277.
[18] TENCENT. Post Training Quantization Tools: ncnn documentation[EB/OL]. [2026-10-31].
[19] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. 2017, 70: 1321-1330.